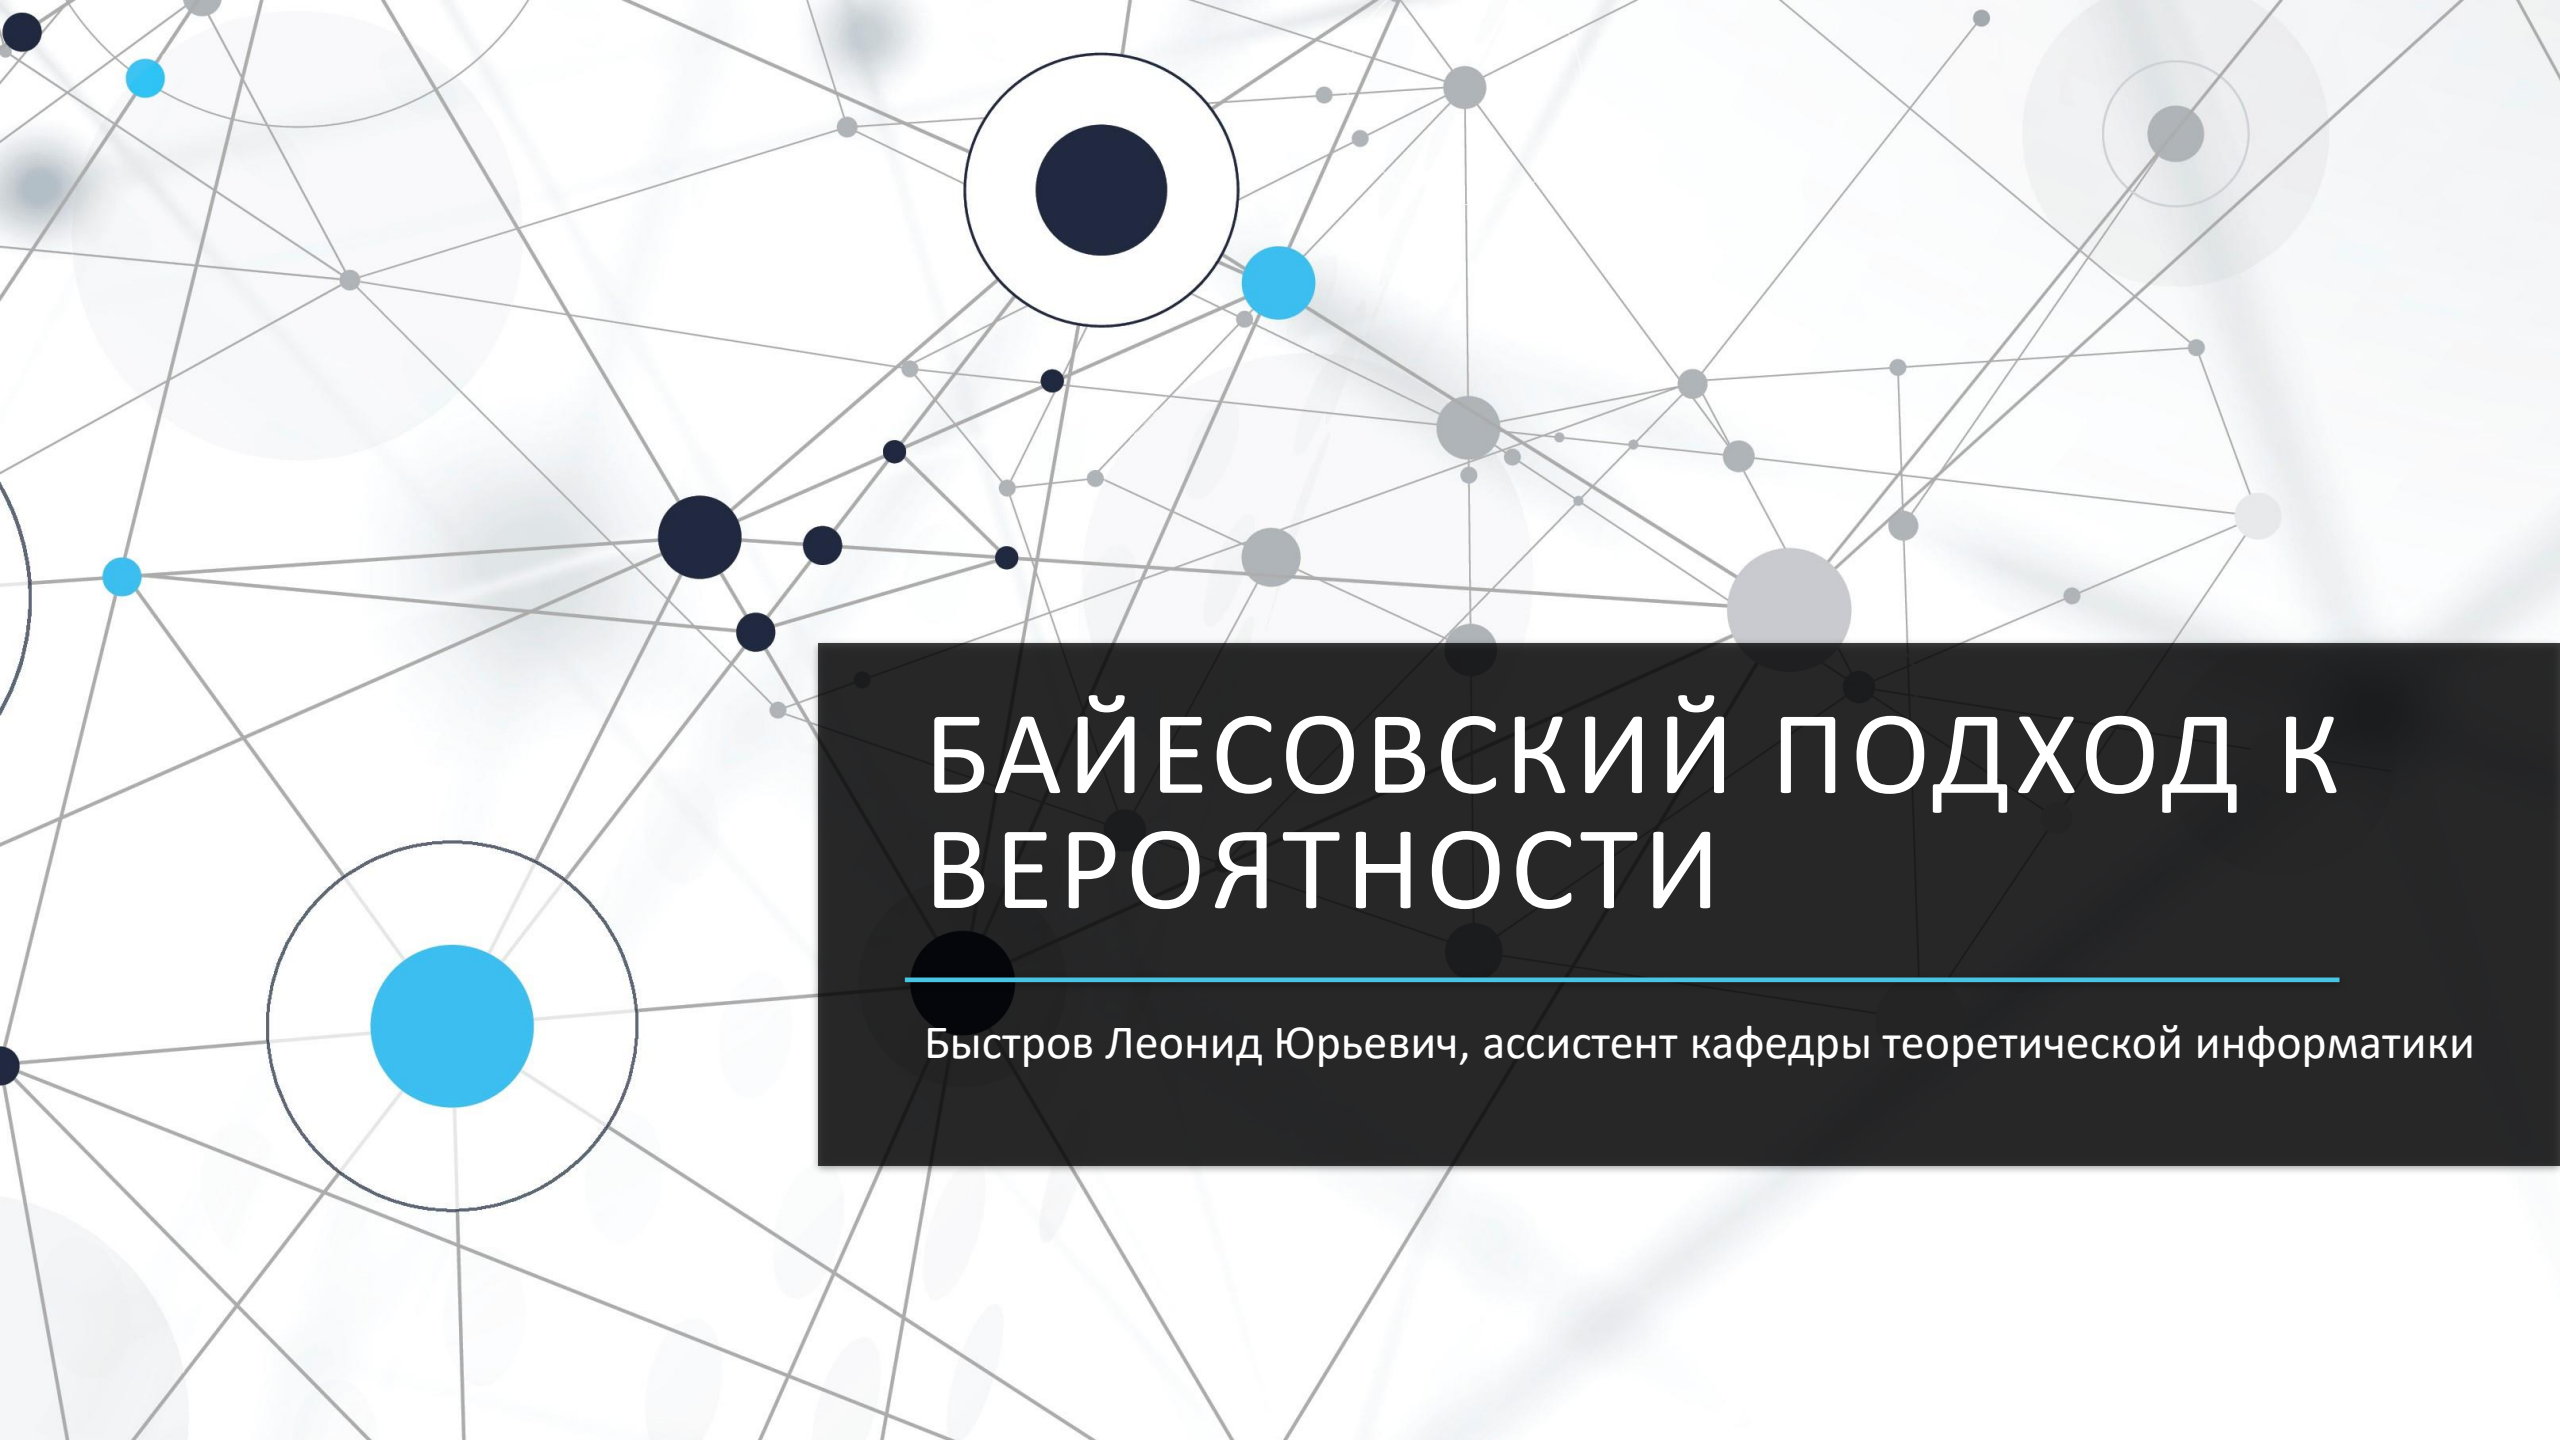


БАЙЕСОВСКИЙ ПОДХОД К ВЕРОЯТНОСТИ

Быстров Леонид Юрьевич, ассистент кафедры теоретической информатики

ВЕРОЯТНОСТЬ

Дискретный случай: $\Omega = \{\omega_1, \omega_2 \dots, \omega_n, \dots\}$ – пространство элементарных событий (счётное множество). Вероятностью называется функция $P: \Omega \to [0; 1]$, такая, что $\sum_i P(\omega_i) = 1$.

Непрерывный случай: $\mathcal{S}$ – сигма-алгебра на Ω.
Вероятностью называется функция P: $\mathcal{S} \to [0; 1]$, такая, что

- $\mathrm{P}(\Omega) = 1$,
- Если $S_1, S_2, \dots, S_n, \dots$ – счётное множество непересекающихся множеств в $\mathcal{S}$, то есть $S_i \in \mathcal{S}$ и $S_i \cap S_j = \emptyset$ для $\forall i \neq j$, то $P(\bigcup_i S_i) = \sum_i P(S_i)$,
- Если $S_1 \supseteq S_2 \supseteq \cdots \supseteq S_n \supseteq \cdots$ – такая последовательность множеств из $\mathcal{S}$, что $\bigcap_i S_i = \emptyset$, то $p(S_n) \to 0$ при $n \to \infty$.

СЛУЧАЙНАЯ ВЕЛИЧИНА

Случайной величиной на вероятностном пространстве $(\Omega, \mathcal{S}, P)$ называется функция $X: \Omega \to R$, прообразы которой лежат в $\mathcal{S}$ (измеримость).

Функция распределения случайной величины X: $F_X(x) = P(X \leq x)$.

Непрерывная случайная величина имеет функцию плотности распределения $p(t)$: $\int_{-\infty}^{x} p(t)dt = F_X(x)$.

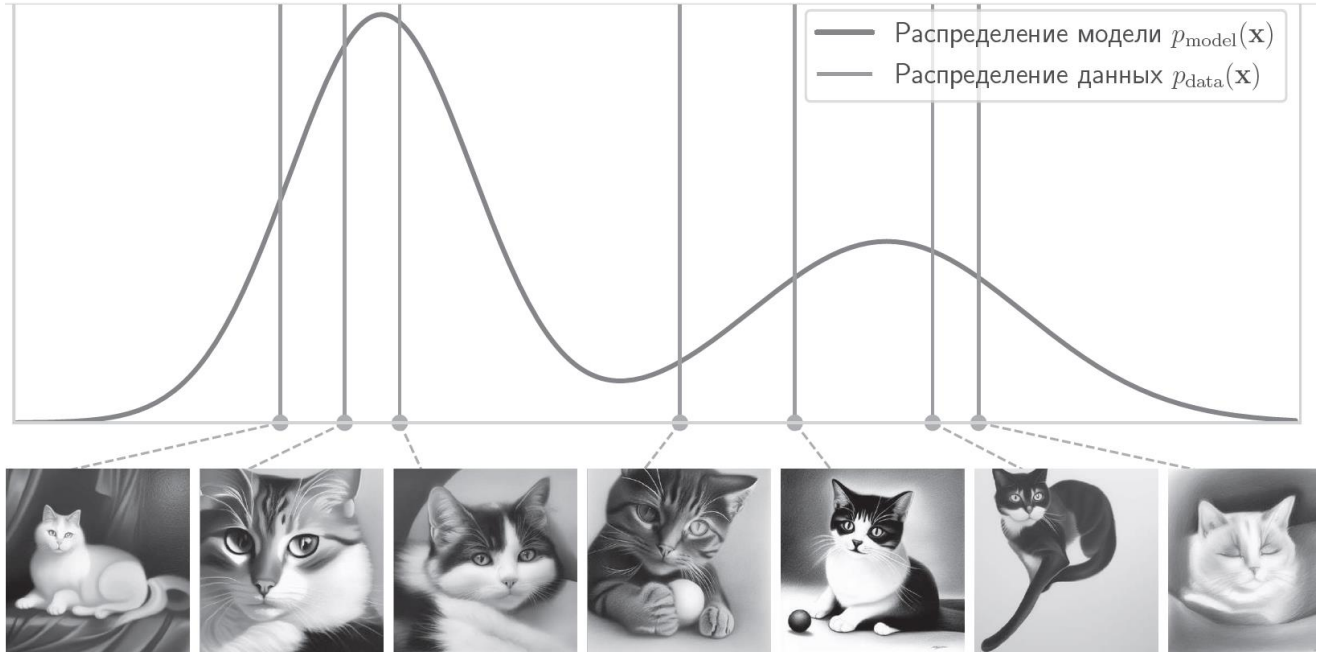
У дискретных случайных величин, вообще говоря, нет плотности. Но иногда удобно считать, что она есть. В этом случае приходится использовать **обобщённые функции**, например, **дельта-функцию Дирака**:

$$\delta(x) = 0 \text{ для } \forall x \neq 0, \int_{-\infty}^{+\infty} \delta(x)dx = 1.$$

РАСПРЕДЕЛЕНИЕ ДАННЫХ

Дискретное распределение точек $\left\{-1, 0, 1, \frac{5}{2}\right\}$ можно представить как смесь дельта-функций:

$$p(x) = \frac{1}{4}\delta(x+1) + \frac{1}{4}\delta(x) + \frac{1}{4}\delta(x-1) + \frac{1}{4}\delta\left(x - \frac{5}{2}\right).$$



ХАРАКТЕРИСТИКИ СЛУЧАЙНЫХ ВЕЛИЧИН

Математическое ожидание

- Дискретный случай: $\mathbb{E}X = \sum_i X_i \cdot P(X = X_i)$.
- Непрерывный случай: $\mathbb{E}X = \int_{-\infty}^{+\infty} tp(t)dt$.

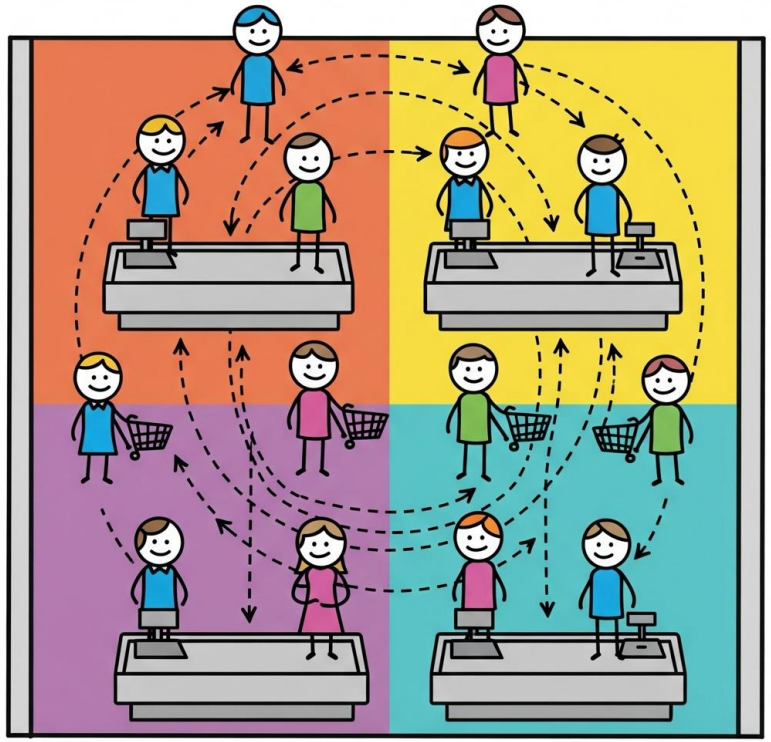
Дисперсия

- $\operatorname{Var} X = \mathbb{E}(X - \mathbb{E}X)^2 = \sum_i (X_i - \mathbb{E}X)^2 P(X = X_i)$.
- $\operatorname{Var} X = \mathbb{E}(X - \mathbb{E}X)^2 = \int_{-\infty}^{+\infty} (t - \mathbb{E}X)^2 p(t)dt$.

Ковариация

- $\operatorname{cov}(X, Y) = \mathbb{E}\big((X - \mathbb{E}X)(Y - \mathbb{E}Y)\big) = \sum_i \sum_j (X_i - \mathbb{E}X)\big(Y_j - \mathbb{E}Y\big)P(X = X_i)P\big(Y = Y_j\big)$.
- $\operatorname{cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y = \iint_{-\infty}^{+\infty} xyp_{X,Y}(x, y)dxdy - \mathbb{E}X \cdot \mathbb{E}Y$.

ОСНОВНЫЕ ВИДЫ ДИСКРЕТНЫХ РАСПРЕДЕЛЕНИЙ



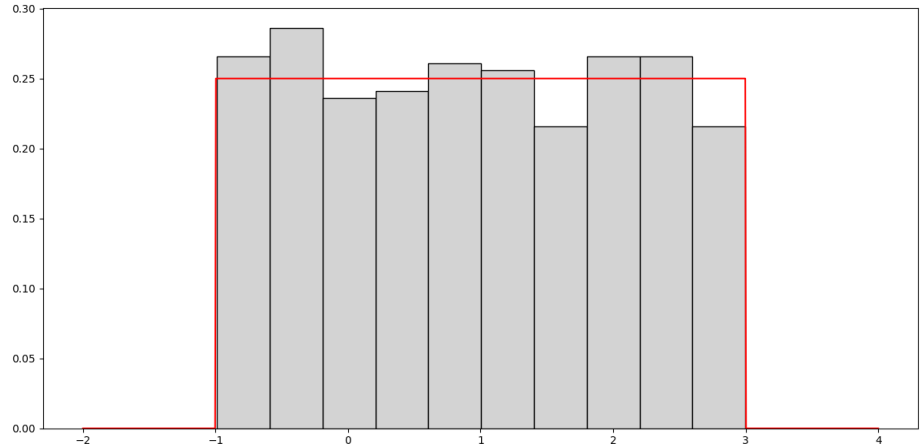


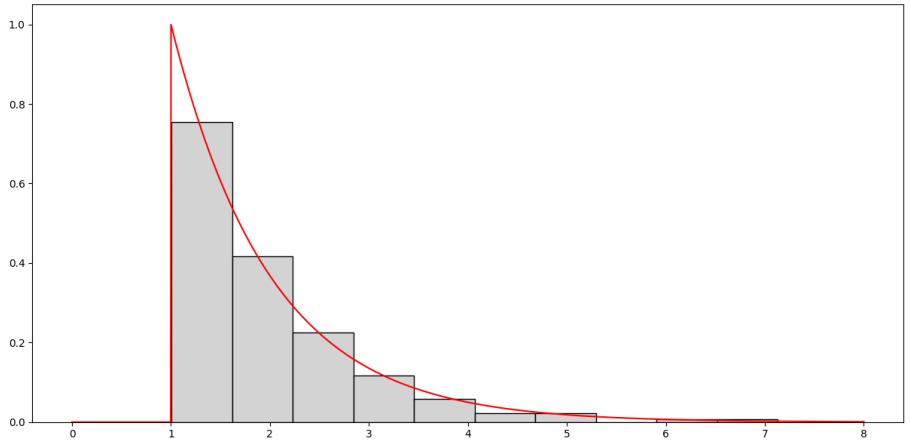


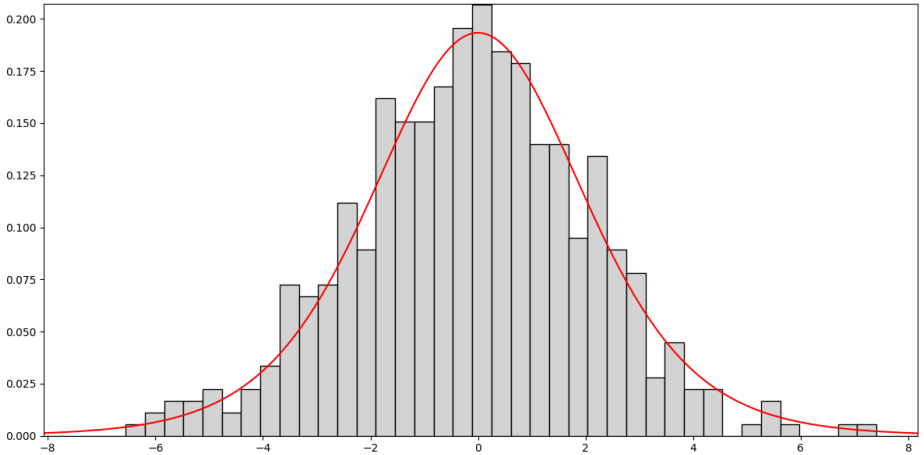


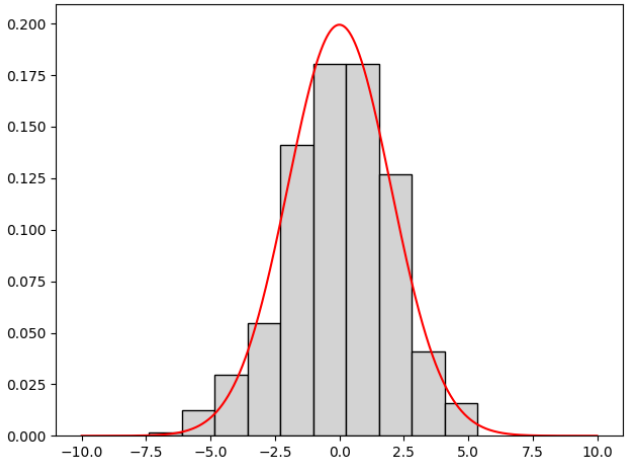
Догадайтесь, какими дискретными распределениями описываются процессы, изображённые на рисунках. Вспомните, как выглядят функция распределения, математическое ожидание и дисперсия этих распределений.

ОСНОВНЫЕ ВИДЫ НЕПРЕРЫВНЫХ РАСПРЕДЕЛЕНИЙ





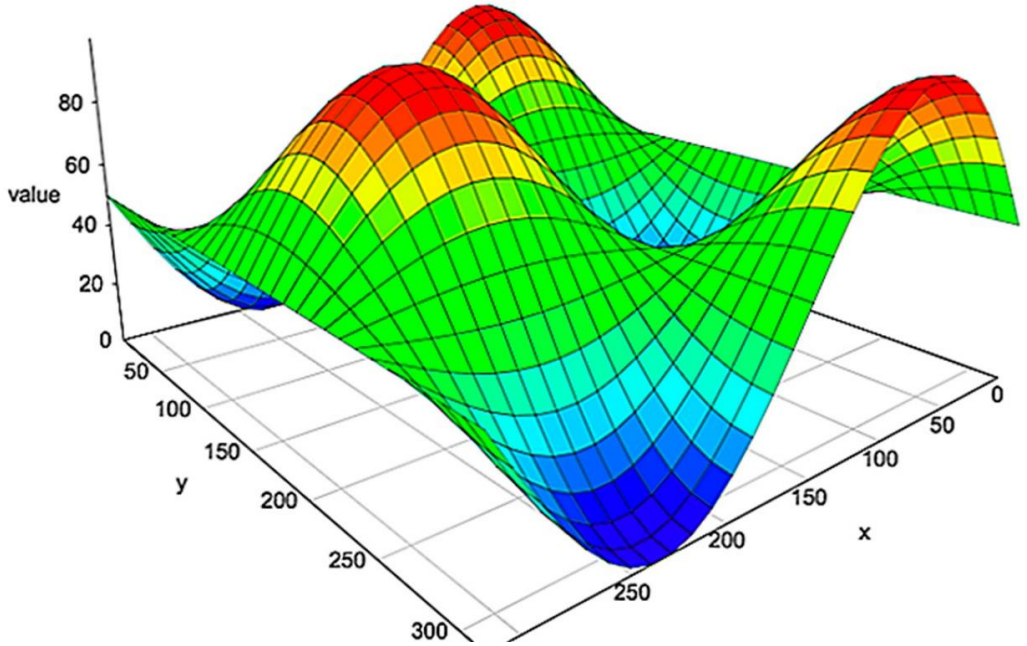






А это что за распределения?

МНОГОМЕРНЫЕ РАСПРЕДЕЛЕНИЯ



В машинном обучении распределения всегда являются многомерными. В этом случае рассматриваются **совместные** случайные величины и, соответственно, вероятности совместных величин $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$.

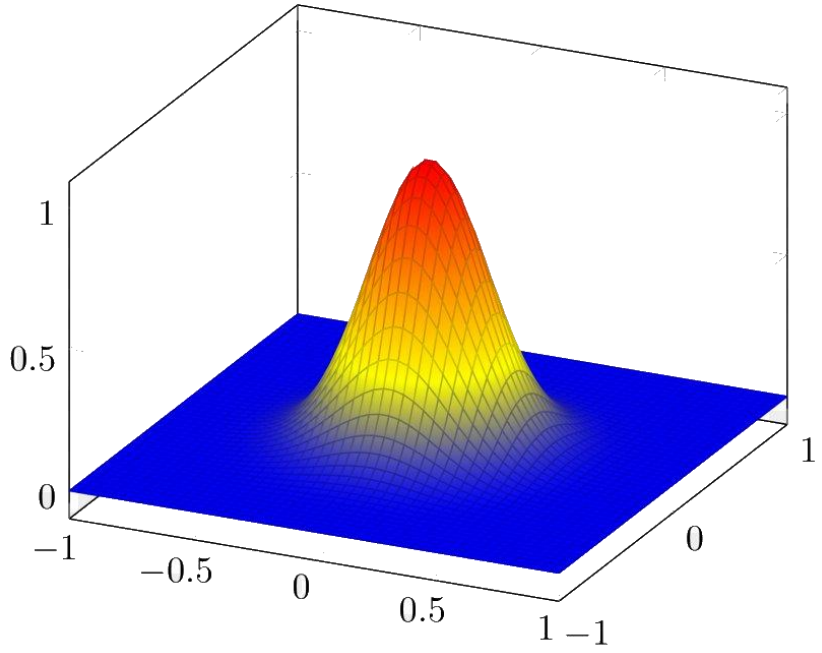
МНОГОМЕРНЫЕ РАСПРЕДЕЛЕНИЯ

Плотность многомерного нормального распределения:

$$p(x_1, x_2, \ldots, x_n) = \frac{1}{\sqrt{(2\pi)^n \det \Sigma}} e^{-\frac{1}{2}(\bar{x}-\bar{\mu})^{\mathrm{T}}\Sigma^{-1}(\bar{x}-\bar{\mu})},$$

где $\bar{x}^{\mathrm{T}} = (x_1, x_2, \ldots, x_n)$.







Найдите, чему равно $\mathbb{E}(X_i X_j)$ многомерного нормального распределения. Подсказка: оно как-то связано с матрицей Σ.

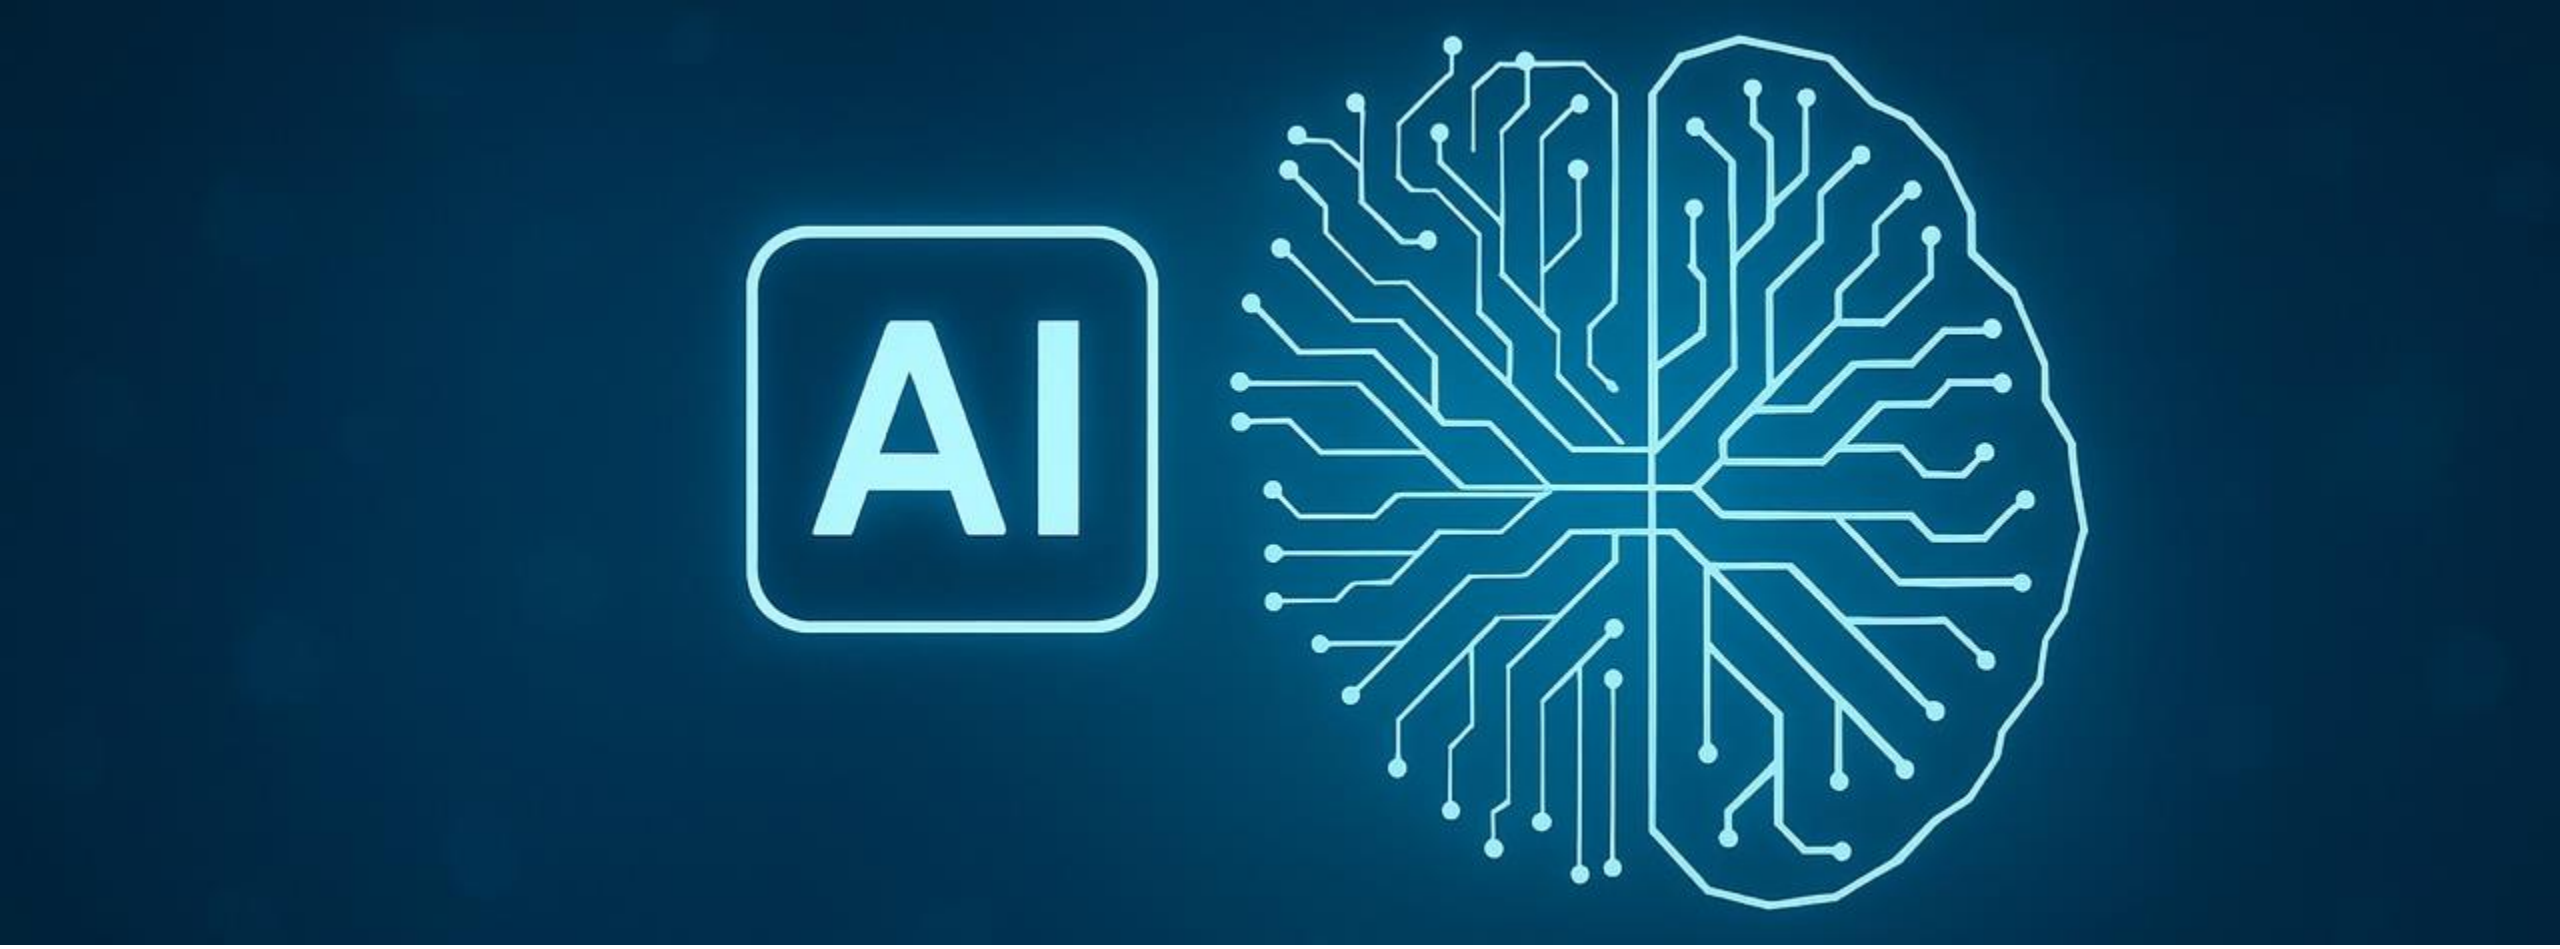
ФУНКЦИЯ ПРАВДОПОДОБИЯ

Пусть $x_1, x_2, \dots, x_n$ – *выборка*, порождённая случайной величиной X. Распределение X имеет параметры $\overline{\Theta} = (\Theta_1, \Theta_2, \dots, \Theta_m)$. **Функцией правдоподобия** называется величина

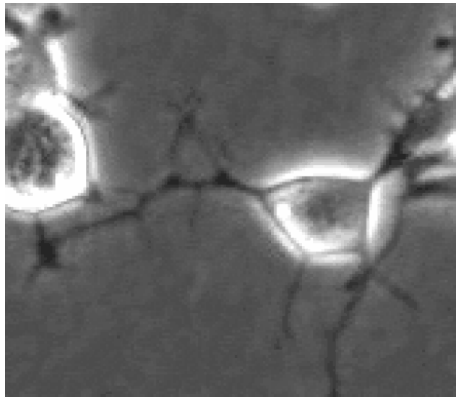
$$\mathcal{L}(x_1, x_2, \dots, x_n, \Theta_1, \Theta_2, \dots, \Theta_m) = \prod_{i=1}^{n} p_X(x_i|\overline{\Theta}).$$

Максимизация функции правдоподобия максимизирует *вероятность данных* $P(x_1, x_2, \dots, x_n|\overline{\Theta})$, хотя само правдоподобие вероятностью является не всегда.

Популярным методом оценки параметров $\Theta_1, \Theta_2, \dots, \Theta_m$ является нахождение максимумов функции правдоподобия. Такой метод называется **методом максимального правдоподобия** (Maximal Likelihood Method, ML Method).



БАЙЕСОВСКИЕ РАССУЖДЕНИЯ



УСЛОВНАЯ ВЕРОЯТНОСТЬ

Совместная вероятность – вероятность одновременного наступления 2 событий $P(X = i, Y = j)$.

Маргинализация:

- Дискретный случай: $P(X = i) = \sum_j P(X = i, Y = j)$.
- Непрерывный случай: $p(x) = \int_{-\infty}^{+\infty} p(x, y)dy$.

Условная вероятность – вероятность наступления одного события, если известно, что произошло другое $P(X = i|Y = j)$.

$$P(X = i|Y = j) = \frac{P(X = i, Y = j)}{P(Y = j)}.$$

УСЛОВНАЯ ВЕРОЯТНОСТЬ

У моего знакомого два ребёнка. Будем предполагать, что пол ребёнка выбирается независимо и равновероятно с вероятностью 0,5.

Две постановки вопроса:

- Я спросил, есть ли у него мальчики, и он ответил «да»; какова вероятность того, что один из детей – девочка?
- Я встретил одного из его детей, и это мальчик; какова вероятность того, что второй ребёнок – девочка?

УСЛОВНАЯ ВЕРОЯТНОСТЬ

У моего знакомого два ребёнка. Будем предполагать, что пол ребёнка выбирается независимо и равновероятно с вероятностью 0,5.

Две постановки вопроса:

- Я спросил, есть ли у него мальчики, и он ответил «да»; какова вероятность того, что один из детей – девочка?
- Я встретил одного из его детей, и это мальчик; какова вероятность того, что второй ребёнок – девочка?

Из-за разного качества информации (неопределённая/конкретная) получаются разные вероятности.

ТЕОРЕМА БАЙЕСА

Из определения условной вероятности выводится центральная формула нашего курса:

$$P(X|Y) = \frac{P(X) \cdot P(Y|X)}{P(Y)}$$

Вывод: $P(X,Y) = P(Y)P(X|Y) = P(X)P(Y|X)$.

ТЕОРЕМА БАЙЕСА

Из определения условной вероятности выводится центральная формула нашего курса:

$$P(X|Y) = \frac{P(X) \cdot P(Y|X)}{P(Y)}$$

Вывод: $P(X,Y) = P(Y)P(X|Y) = P(X)P(Y|X)$.

Среди определенной группы людей вероятность некоторой болезни 0,02. Тест, позволяющий выявить болезнь, несовершенен. На больном он дает позитивный результат в 98 случаях из 100, и, кроме того, он даёт позитивный результат в 4 случаях из 100 на здоровом. Найдите вероятность того, что человек, на котором тест дал положительный результат, действительно болен.

ФРЕКВЕНТИСТСКАЯ ИНТЕРПРЕТАЦИЯ ВЕРОЯТНОСТИ

Обычно в классической теории вероятностей вероятность понимается как предел отношения количества определённого результата эксперимента к общему количеству экспериментов.

Пример: бросание монетки.

Если после 100 подбрасываний монетки выпало 54 орла, то вероятность выпадения орла приблизительно равна $\frac{54}{100}$.

В общем случае, вероятность выпадения орла равна $\lim_{n\to\infty} \frac{S_n}{n}$, где S_n – количество выпавших орлов в n экспериментах.

БАЙЕСОВСКАЯ ИНТЕРПРЕТАЦИЯ ВЕРОЯТНОСТИ

Мы можем рассуждать о том, насколько вероятно, что

1) Сборная России победит на чемпионате мира по футболу в 2026 году.

2) «Одиссею» написала женщина.

3) Александр Керенский бежал за границу в женском платье.

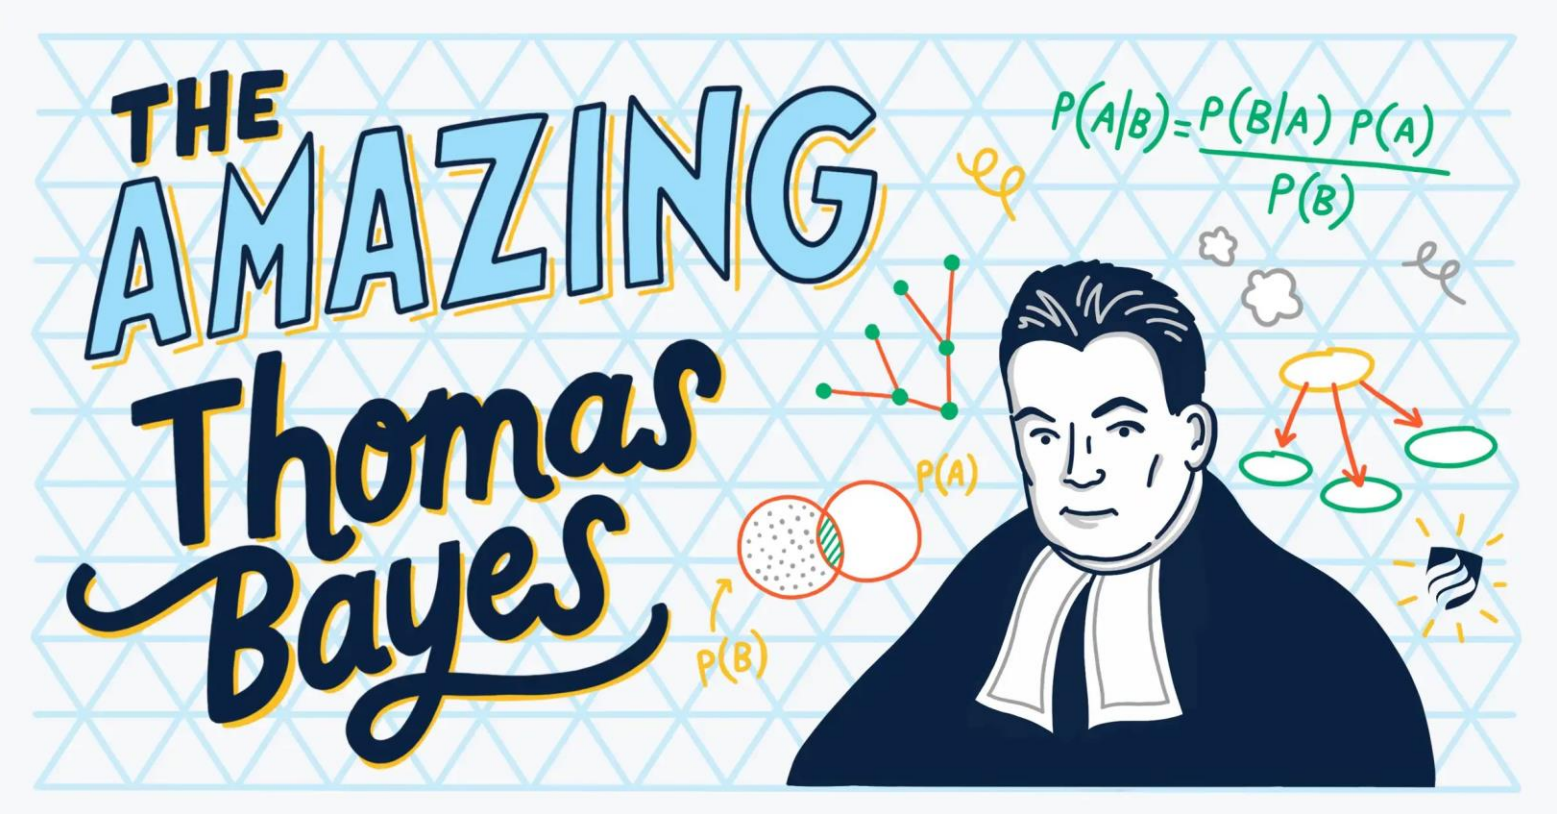
4) …

О стремящемся к бесконечности количестве экспериментов говорить бессмысленно – эксперимент здесь ровно один.

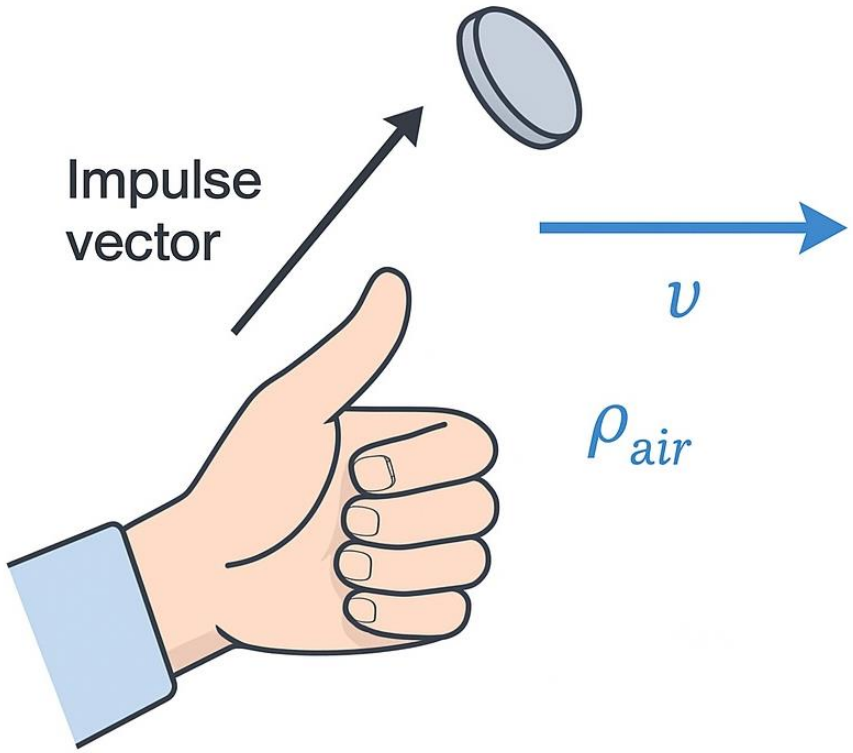
Вероятности тут выступают как *степени доверия*. Это и есть байесовский подход к вероятности.

ТОМАС БАЙЕС

Главный труд его жизни – «О Божественном предопределении»



БАЙЕС ОБЪЯСНЯЕТ, ЧТО ТАКОЕ ВЕРОЯТНОСТЬ



Если бы мы знали все физические параметры подброса монетки, то могли мы сказать, какой стороной она упадёт.

Но мы этого не знаем! Поэтому приходится рассуждать о вероятностях.

С точки зрения Т. Байеса, точное знание принадлежит Богу, а человеку – вероятностное.

УСЛОВНЫЕ РАСПРЕДЕЛЕНИЯ

Плотность условных распределений определяется аналогично условной вероятности: $p(x|y) = \frac{p(x,y)}{p(y)}$, $p(y) > 0$.

Формула *полной вероятности* в непрерывном случае:

$$p(x) = \int_{-\infty}^{+\infty} p(y)p(x|y)dy\,.$$

Два события называются **независимыми**, если $P(X,Y) = P(X) \cdot P(Y)$.

Два величины называется **независимыми**, если $p(x,y) = p(x) \cdot p(y)$ для любых x, y – значений соответствующих случайных величин.

НЕЗАВИСИМОСТЬ СЛУЧАЙНЫХ ВЕЛИЧИН

Величины $X_1, X_2, \dots, X_n$ называются **независимыми в совокупности**, если $p(x_1, x_2, \dots, x_n) = p(x_1)p(x_2)\cdots p(x_n)$ для любых $x_1, x_2, \dots, x_n$ – значения соответствующих случайных величин.

Попарная независимость и независимость в совокупности это не одно и то же!



Подумайте, почему это правда? Человек справа намекает вам на какой-то свой известный парадокс…



УСЛОВНАЯ НЕЗАВИСИМОСТЬ

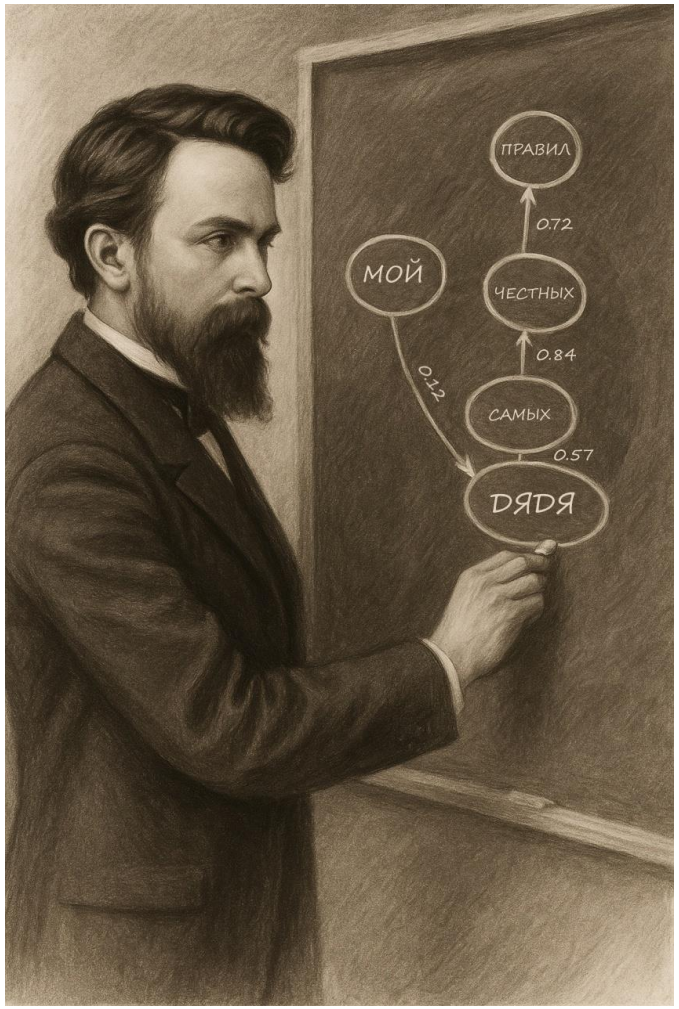
События X и Y **условно независимы** при условии Z, если $\mathrm{P}(X|Y,Z) = P(X|Z)$.

Величины X и Y **условно независимы** при условии Z, если $p(x|y,z) = p(x|z)$ для любых x, y, z – значений соответствующих величин.

Основным вероятностным предположением в машинном обучении является условная независимость точек данных при условии параметров модели. Без этого предположения не удаётся провести почти никакие вычисления…

Как в случае независимых событий, совместная вероятность условно независимых событий равна произведению условных вероятностей: $P(X,Y|Z) = P(X|Z) \cdot P(Y|Z)$.

МАРКОВСКОЕ СВОЙСТВО



Последовательность событий $A_1, A_2, \dots, A_t, \dots$ называется **марковской цепью**, если выполнено **марковское свойство**:

$$P(A_{t+1}|A_t, A_{t-1}, \dots A_1) = P(A_{t+1}|A_t), \forall t \in \mathbb{N}.$$

Марковское свойство означает, что будущее целиком определяется настоящим и прошлое уже не важно.

Цепи Маркова – очень популярный объект в теории вероятности и случайных процессах. В машинном обучении они тоже играют далеко не последнюю роль…

А. А. Марков Старший (1856-1922)

БАЙЕСОВСКИЕ ОПРЕДЕЛЕНИЯ

Пусть D – данные эксперимента, Θ – вектор параметров модели, тогда в формуле

$$p(\Theta|D) = \frac{p(\Theta) \cdot p(D|\Theta)}{p(D)}$$

$p(D|\Theta)$ называется **функцией правдоподобия**,

$p(\Theta)$ – **априорной вероятностью**,

$p(\Theta|D)$ **– апостериорной вероятностью**,

$p(D) = \int p(\Theta) \cdot p(D|\Theta) d\Theta$ **– вероятность данных**.

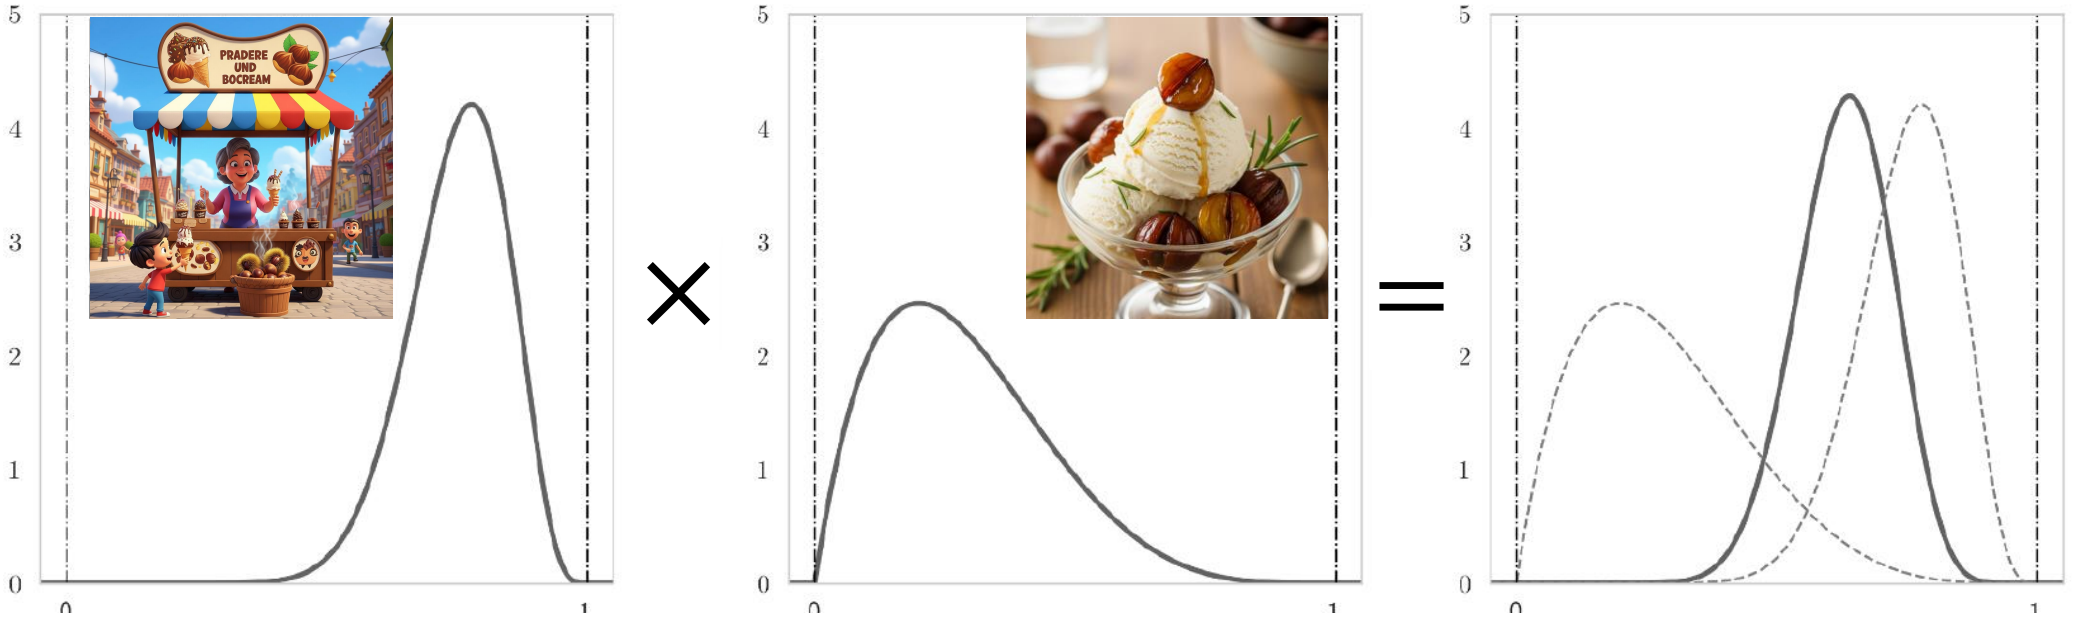
МОРОЖЕНОЕ С ЖАРЕНЫМИ КАШТАНАМИ



Предположим, что Вам предложили попробовать мороженое с жареными каштанами, которого раньше Вы не пробовали.

Параметр $\Theta \in [0; 1]$ – то, насколько Вам понравится вкус мороженого.

МОРОЖЕНОЕ С ЖАРЕНЫМИ КАШТАНАМИ



$p(\Theta)$

Будем считать, что, в целом, Вы любите есть мороженое.

$p(D|\Theta)$

Вы попробовали 1 мороженое и оно оказалось так себе.

$p(\Theta|D)$

Ваше представление о мороженом с жареными каштанами изменилось.

БАЙЕСОВСКИЕ ОПРЕДЕЛЕНИЯ

Таким образом,

- $p(\Theta)$ соответствует знанию о модели данных до того, как сами данные были получены.
- $p(D|\Theta)$ отражает, насколько данные соответствуют модели.
- $p(\Theta|D)$ соответствует изменившемуся знанию о модели данных после того, как были получены сами данные.

Число $p(D)$ является просто нормирующей константой и особого смысла не несёт. Оно необходимо, чтобы $p(\Theta|D)$ оставалось в промежутке $[0; 1]$.

Обучение модели – это изменение её параметров в зависимости от данных, то есть пересчёт её апостериорной вероятности.

БАЙЕСОВСКИЙ МЕТОД ОЦЕНКИ ПАРАМЕТРОВ

В статистике обычно ищут **гипотезу максимального правдоподобия**

$$\Theta_{ML} = arg\max_{\Theta} p(D|\Theta)\,.$$

В машинном обучении ищут **максимальную апостериорную гипотезу**

$$\Theta_{MAP} = \arg\max_{\Theta} p(\Theta|D) = \arg\max_{\Theta} \frac{p(\Theta)p(\mathrm{D}|\Theta)}{p(D)} =$$
$$= \arg\max_{\Theta} p(\Theta)p(\mathrm{D}|\Theta)\,.$$

ПРЕДСКАЗАТЕЛЬНОЕ РАСПРЕДЕЛЕНИЕ

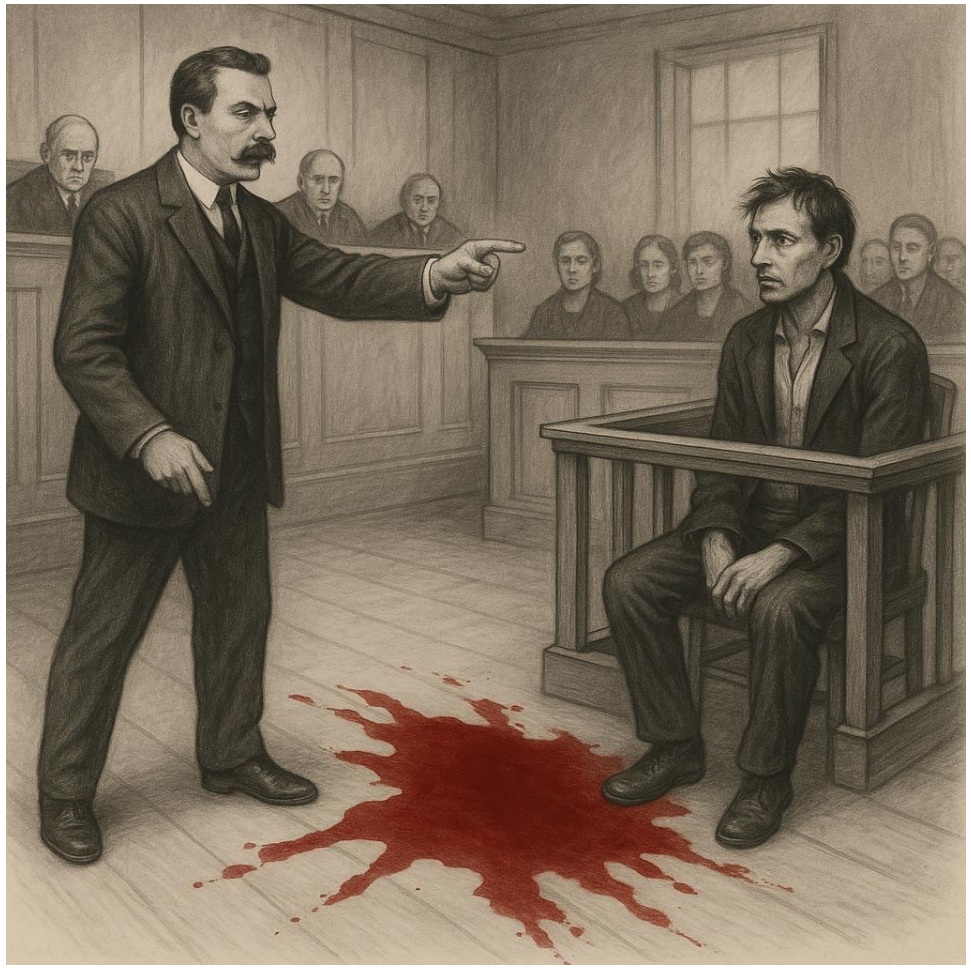
Для того, чтобы понять, с какой вероятностью модель делает разные предсказания, считают **предсказательное распределение** $p(x|D)$

$$p(x|D) = \int p(x, \Theta|D)d\Theta = \int p(\Theta|D) \cdot p(x|\Theta, \mathrm{D})\mathrm{d}\Theta\,.$$

Здесь предполагается, что элемент данных x целиком определяется Θ, то есть x *условно не зависи*т от D при условии Θ:

$$p(x|D) = \int p(\Theta|D) \cdot p(x|\Theta)\mathrm{d}\Theta\,.$$

ОШИБКА ПРОКУРОРА



Произошло убийство. На месте убийства найдена кровь, которая явно принадлежит убийце. Кровь принадлежит редкой группе, которая присутствует у 1% населения, в том числе у подсудимого.

Прокурор говорит: «Шанс, что у подсудимого была бы именно такая группа крови, если бы он был невиновен – всего 1%; значит, с вероятностью 99% он виновен». В чём не прав прокурор?

ОШИБКА ПРОКУРОРА

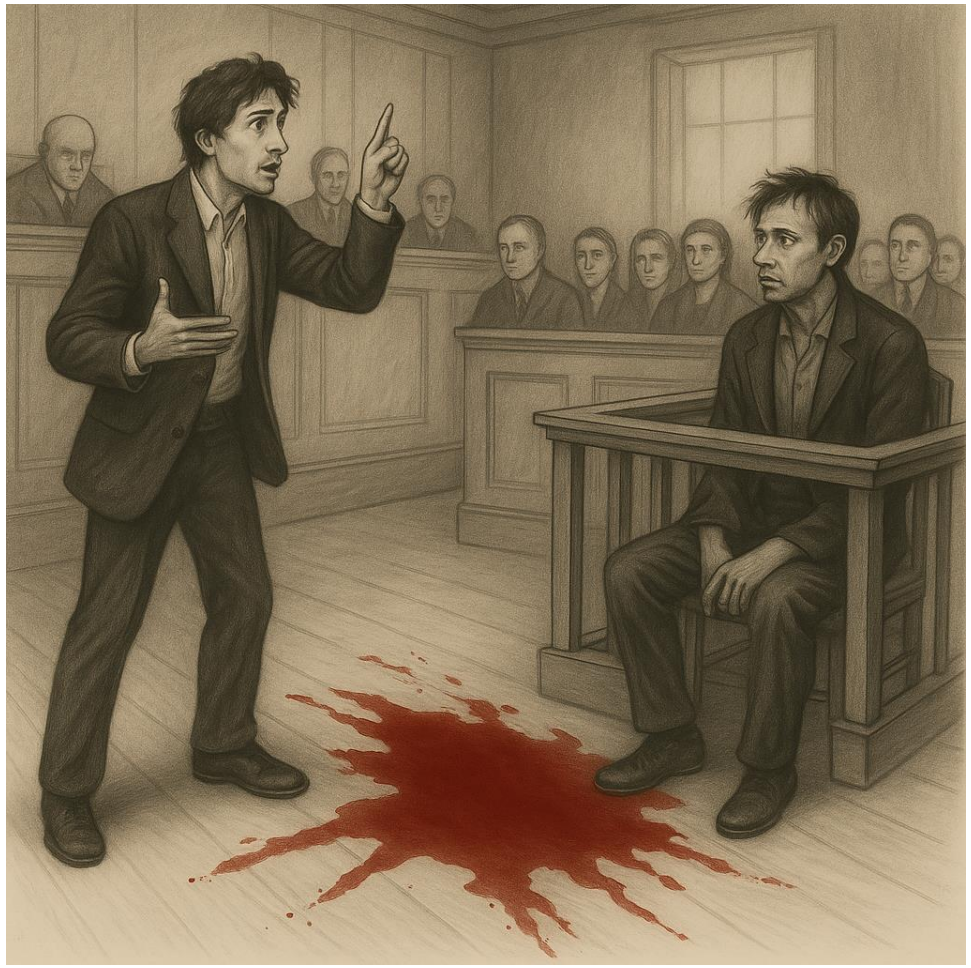
По теореме Байеса:

$$p(\text{«нев}-\text{н»}|\text{«кровь X»}) = p(\text{«кровь X»}|\text{«нев}-\text{н»}) \cdot \frac{p(\text{«нев} - \text{н»})}{p(\text{«кровь } X\text{»})}$$

Если априорная вероятность невиновности (независимо от крови) достаточно высока, то вероятность невиновности подсудимого будет значительно отличаться от предсказания прокурора.

Ошибка прокурора заключается в том, что он путает $p(\text{«кровь X»}|\text{«нев}-\text{н»})$ с $p(\text{«нев}-\text{н»}|\text{«кровь X»})$.

ОШИБКА АДВОКАТА



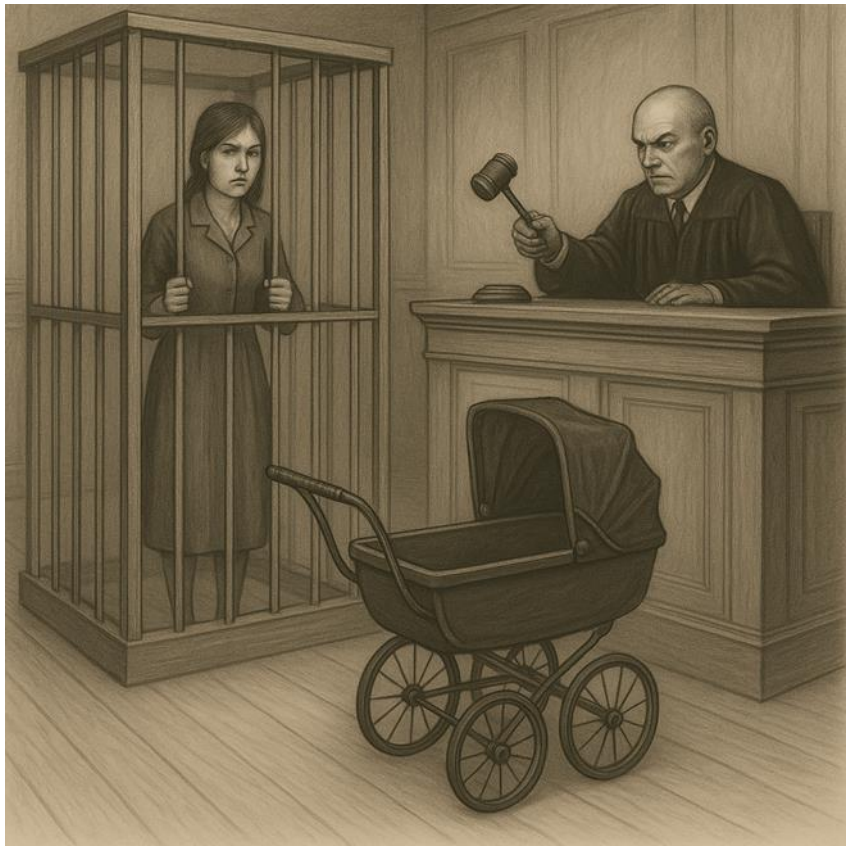
Адвокат говорит: «В городе живёт миллион человек, то есть у 10000 из них такая группа крови. Значит, всё, что говорит нам эта кровь – это то, что подсудимый совершил убийство с вероятностью 0.01%; никакое это не доказательство». В чём не прав адвокат?

ОШИБКА АДВОКАТА

В целом, адвокат верно посчитал вероятность вины подсудимого по теореме Байеса, но в предположении равномерного априорного распределения виновности жителей города, включая младенцев и стариков. Корректное априорное распределение должно учитывать только тех людей, которые могли быть на месте преступления в нужное время.

Ошибка адвоката заключается в слишком общем характере представлений о генеральной совокупности.

JAY SIMPSON И SALLY CLARK





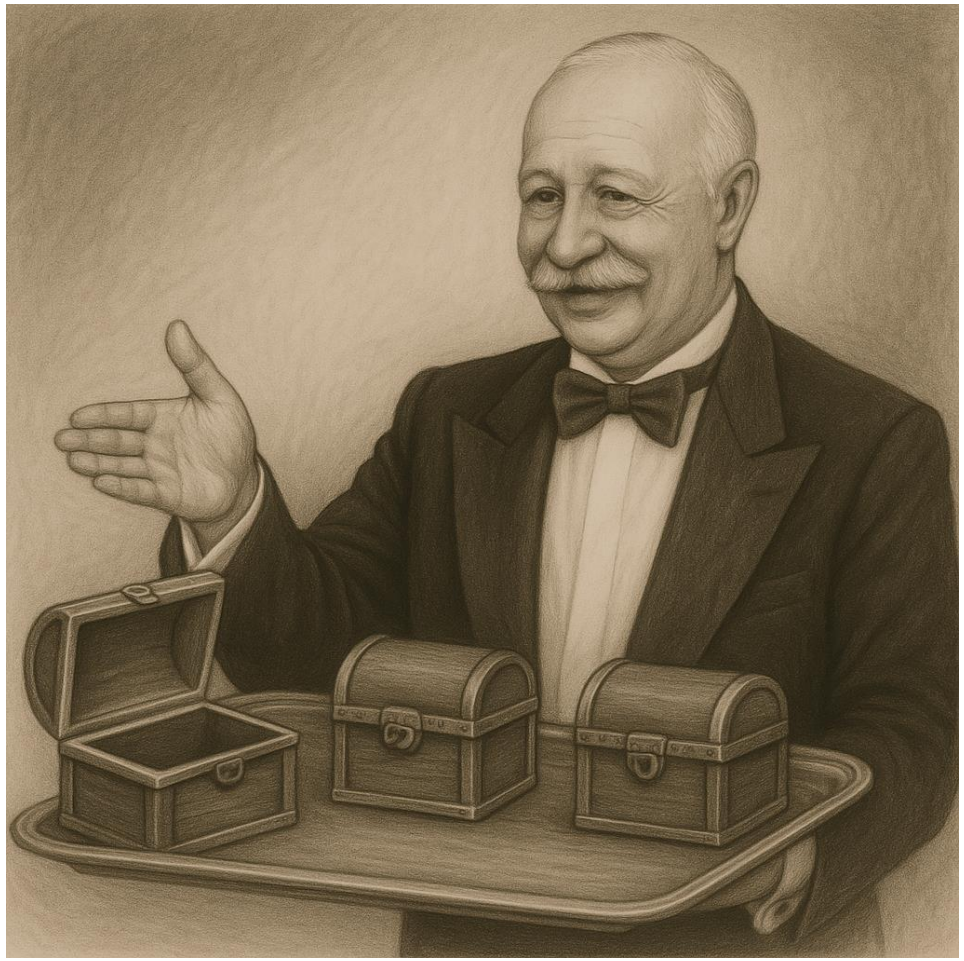
ВЕРОЯТНОСТНЫЕ ОШИБКИ В СТАТИСТИКЕ

Ошибки в рассуждениях о вероятности часто возникают в психологических и социальных науках.

Истинность статистических гипотез обычно оценивают по значению p-value, равному вероятности данных при условии принятия гипотезы. Но для оценки гипотезы следовало бы считать обратную вероятность – гипотезы при условии данных.

Большинство выборок в статистических исследованиях не репрезентативны. Уличные опросы соглашаются проходить не все люди, а только ходящие по улицам и согласные отвечать на вопросы незнакомцев.

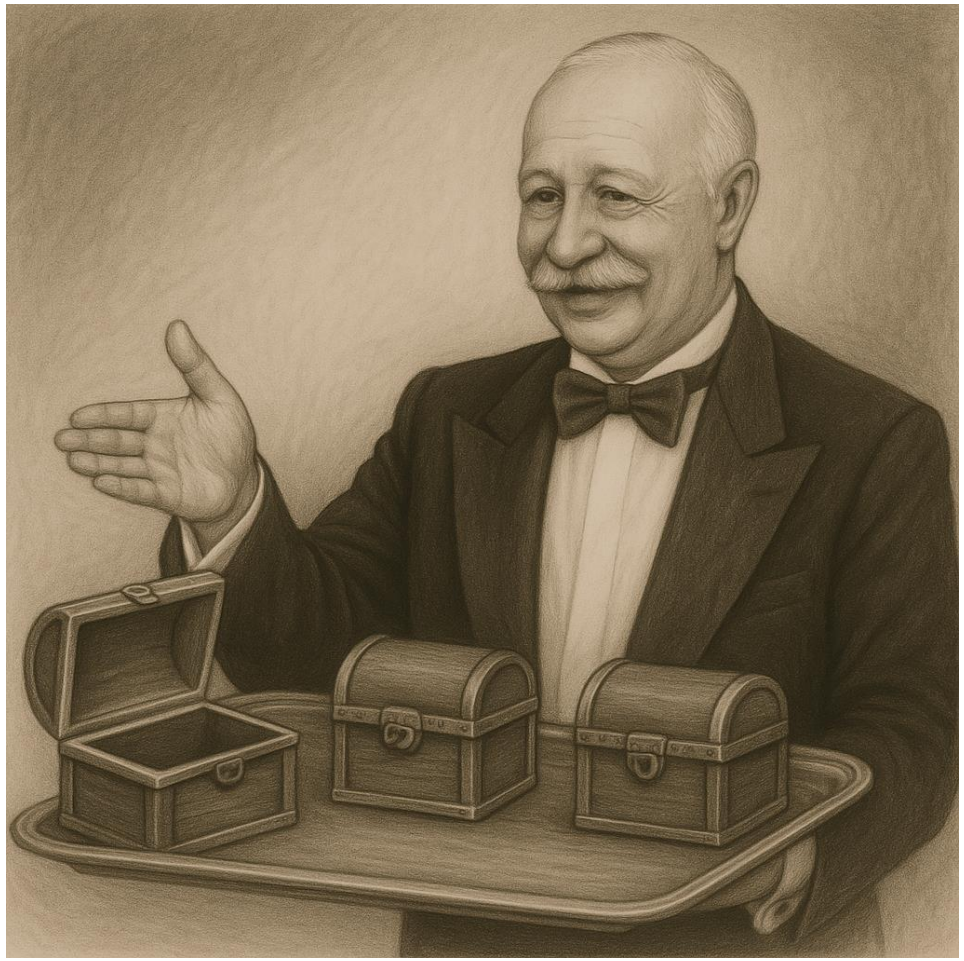
ПАРАДОКС МОНТИ ХОЛЛА



Вы играете в «Поле чудес». Вам предложено на выбор 3 шкатулки. Только в одной из них находится приз. Какую шкатулку Вы выберите?

Ведущий неожиданно открывает одну из шкатулок (не ту, которую Вы выбрали) и показывает, что в ней пусто. Вам вновь предлагается сделать выбор одной из двух оставшихся шкатулок. Будете ли Вы менять свой прежний выбор?

ПАРАДОКС МОНТИ ХОЛЛА



Вы играете в «Поле чудес». Вам предложено на выбор 3 шкатулки. Только в одной из них находится приз. Какую шкатулку Вы выберите?

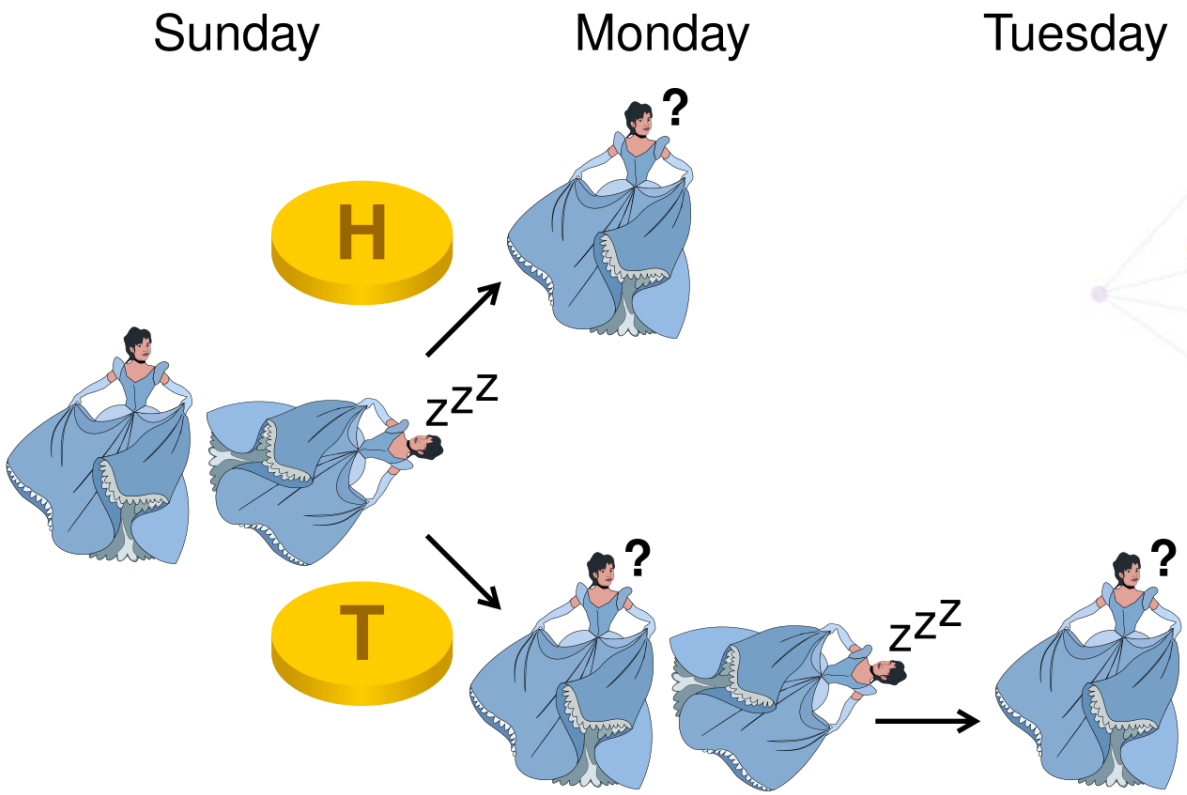
Ведущий неожиданно открывает одну из шкатулок (не ту, которую Вы выбрали) и показывает, что в ней пусто. Вам вновь предлагается сделать выбор одной из двух оставшихся шкатулок. Будете ли Вы менять свой прежний выбор?

Ответ: вероятность, что в другой шкатулке находится приз равна $\frac{2}{3}$.

ЗАДАЧА О СПЯЩЕЙ КРАСАВИЦЕ

В воскресенье Спящую красавицу усыпляют и бросают монетку:

- если выпадает орёл, её будят в понедельник и опять усыпляют до среды.
- если решка, то будят в понедельник, делают укол, от которого она забывает о пробуждении, и будят ещё раз во вторник, а потом так же в среду.

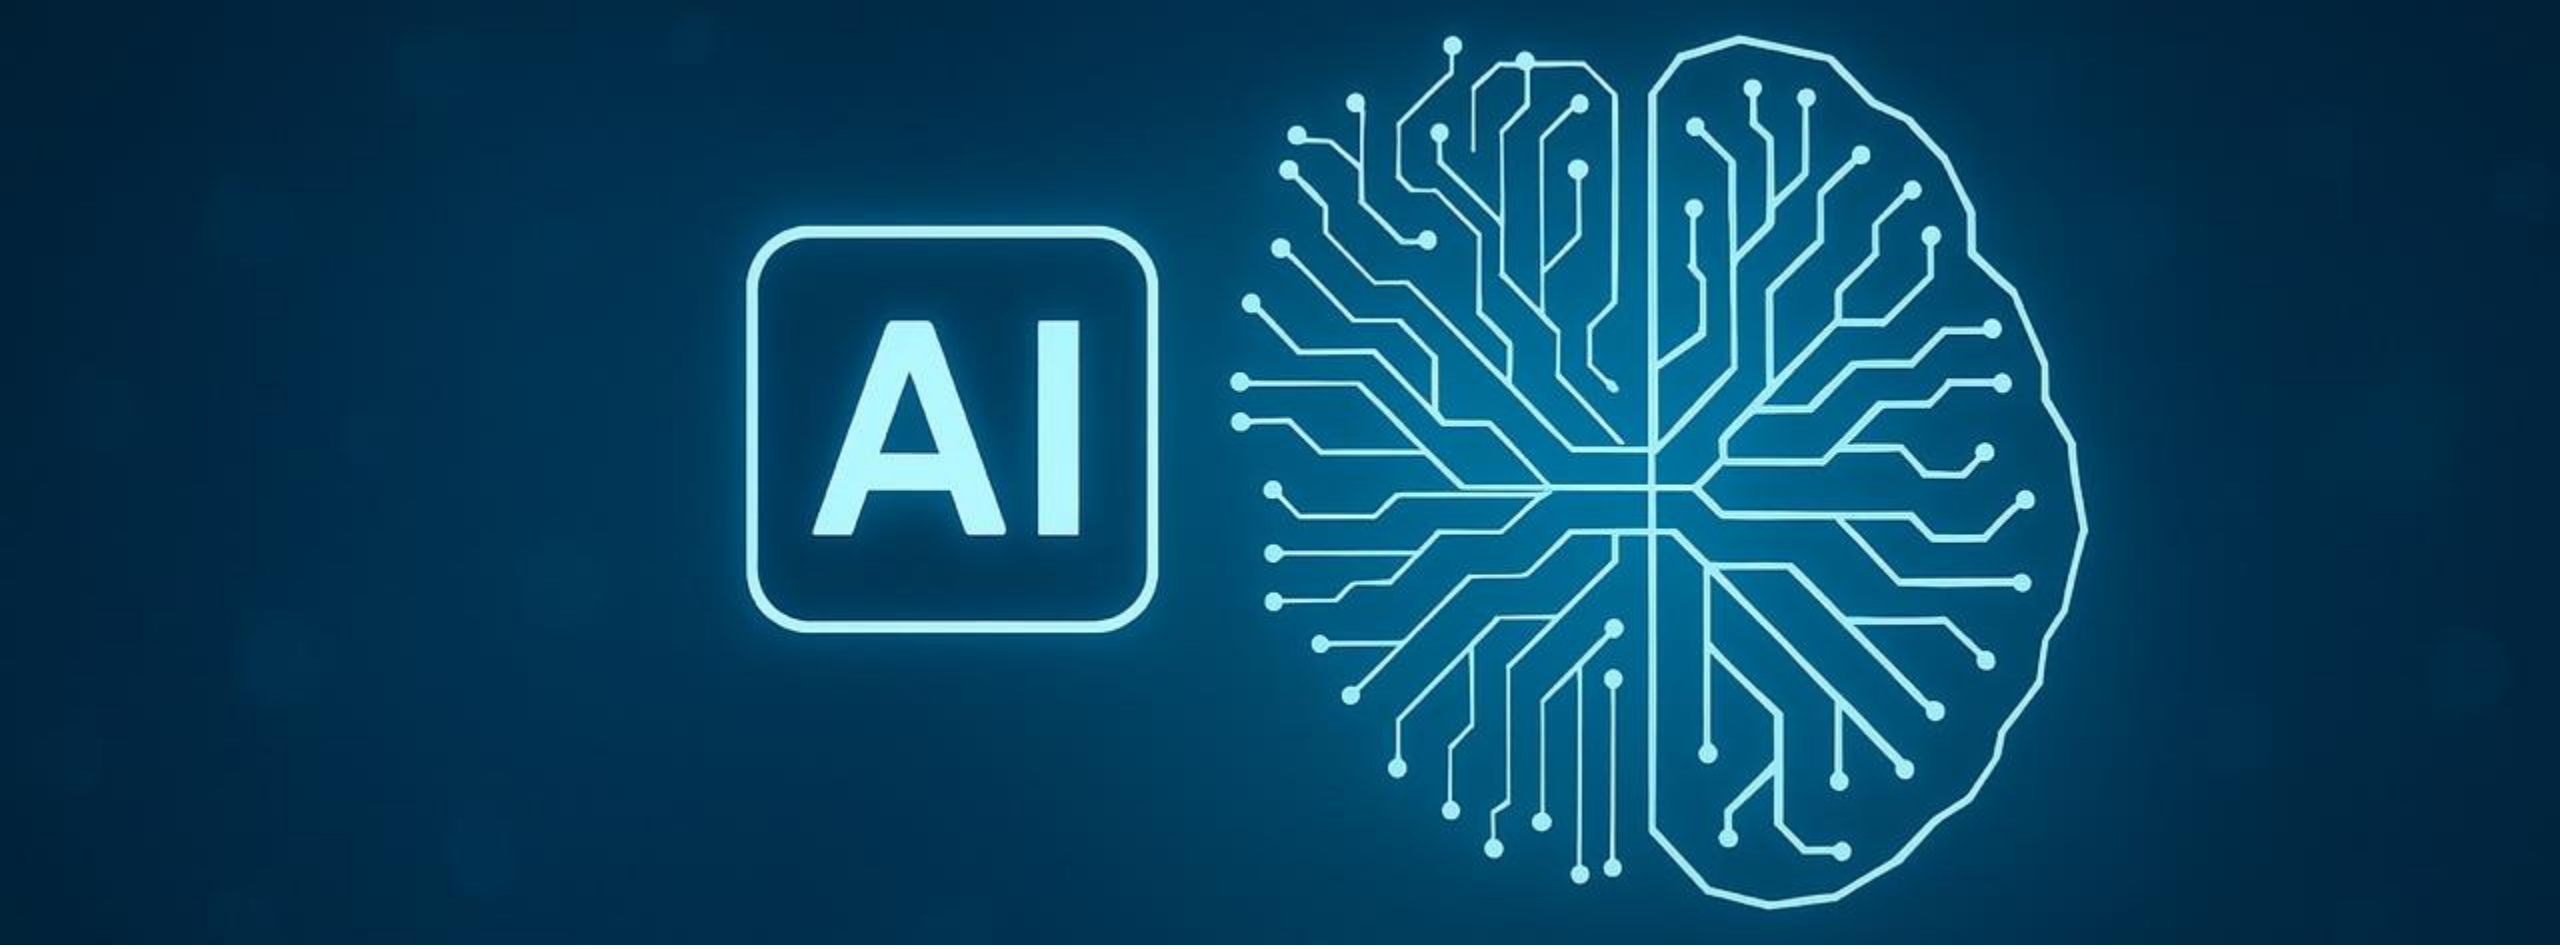


ЗАДАЧА О СПЯЩЕЙ КРАСАВИЦЕ

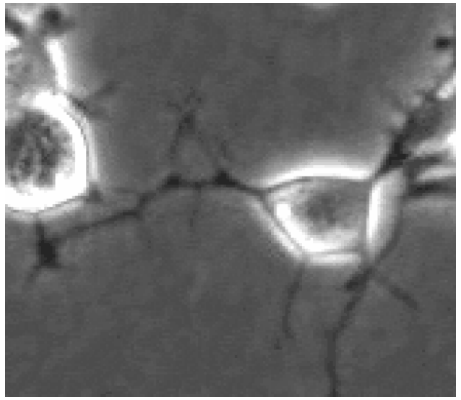
Спящая красавица знает всю процедуру эксперимента, но не может различить разные пробуждения и отличить понедельник от вторника, когда просыпается.



Представьте себя на месте Спящей красавицы. Вас разбудили. Какова вероятность того, что монета упала орлом?



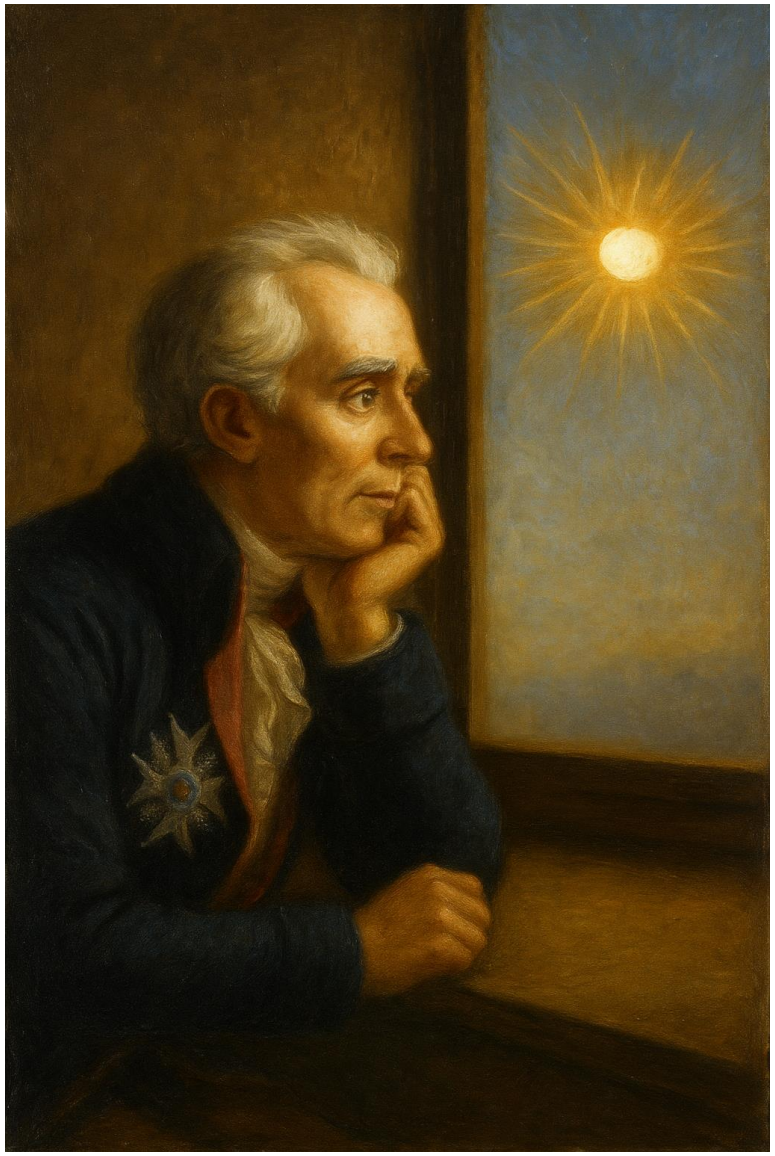
СОПРЯЖЁННЫЕ РАСПРЕДЕЛЕНИЯ



ЗАДАЧА ЛАПЛАСА

«Если мы ничего не знаем о небесной механике, а просто в течение 5000 лет наблюдаем восход Солнца каждое утро, с какой вероятностью мы можем ожидать, что завтра Солнце взойдёт снова?»

Распределение количества дней, когда Солнце взошло, – биномиальное, то есть как у монетки.



ОБУЧЕНИЕ МОНЕТКИ

Набор данных: D=(n, m), n – число орлов, m – число решек.

Параметры: Θ – вероятность выпадения орла.

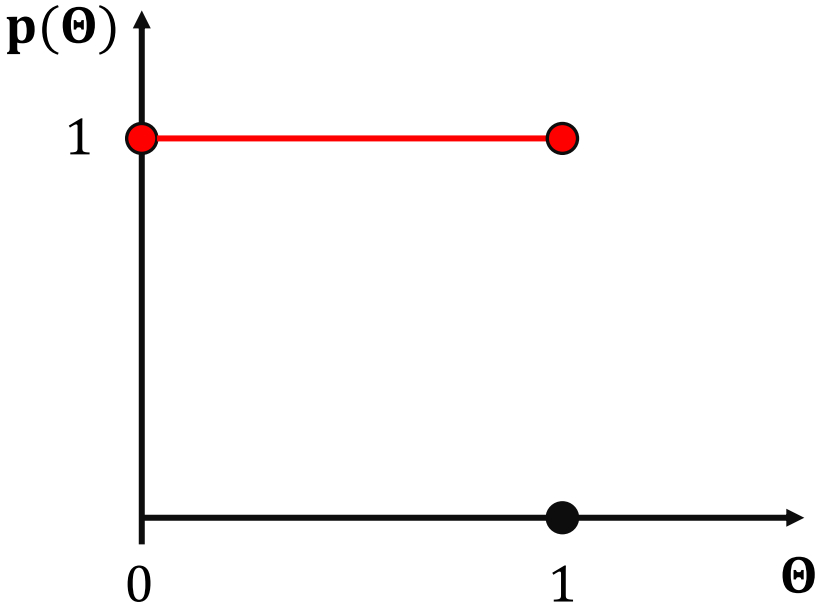
Вспомним теорему Байеса:

$$p(\Theta|D) = \frac{p(\Theta)p(D|\Theta)}{\int p(\Theta)p(D|\Theta)}.$$

Функция правдоподобия находится легко: $p(D|\Theta) = \Theta^n(1-\Theta)^m$.

Априорное распределение $p(\Theta)$ должно отражать наше незнание о том, чему равно Θ. Мы знаем только, что $\Theta \in [0; 1]$.

ОБУЧЕНИЕ МОНЕТКИ



Если всевозможные значения Θ для нас равноценны, то конечно же $p(\Theta)$ будет иметь равномерное распределение.

Оценки максимального правдоподобия и максимальной апостериорной гипотезы совпадают:

$$\Theta_{ML} = \Theta_{MAP} = \frac{n}{n+m}.$$



ОБУЧЕНИЕ МОНЕТКИ



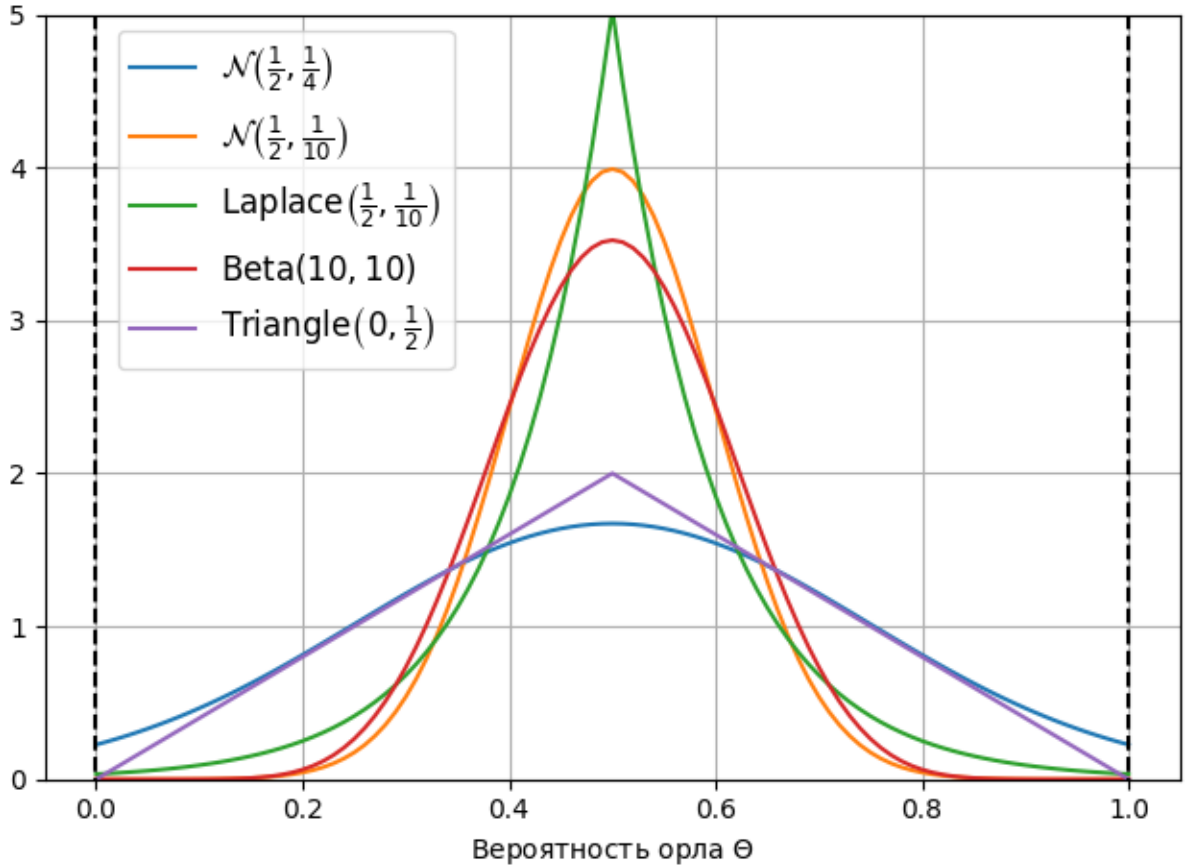
Найдём предсказательное распределение:

$$p(x|\mathrm{D}) = \frac{n+1}{n+m+2}.$$

Предсказания сохраняют нашу неуверенность – вероятность никогда не будет строго равна 0 или 1. Такая поправка называется **лапласовским смещением** или **правилом Лапласа**.

Даже если мы 5 тыс. лет каждый день наблюдали восходы Солнца, вероятность, что оно взойдёт завтра, не равна 1: $p(x|D) = \frac{5\cdot 10^3\cdot 365+1}{5\cdot 10^3\cdot 365+2} = 0.99999945.$

ВЫБОР АПРИОРНОГО РАСПРЕДЕЛЕНИЯ



Как выбрать априорное распределение для монетки?

Понятно, что значения должны быть сосредоточены где-то возле $\frac{1}{2}$, но как именно?

СОПРЯЖЁННЫЕ РАСПРЕДЕЛЕНИЯ

Семейство распределений $\mathcal{P} = \{p(\Theta|\alpha)\}$ является **семейством сопряжённых априорных распределений** для семейства правдоподобий $\mathcal{L} = \{p(D|\Theta)\}$, если апостериорные распределения, получаемые умножением априорных из $\mathcal{P}$ на правдоподобия из $\mathcal{L}$, лежат в $\mathcal{P}$:

$$\forall p(\Theta|\alpha) \in \mathcal{P}, p(D|\Theta) \in \mathcal{L}: p(\Theta|\alpha)p(D|\Theta) \propto p(\Theta|D,\alpha) = \\ = p(\Theta|\alpha') \in \mathcal{P}.$$

α – гиперпараметры, «параметры распределения параметров».

Тривиальный пример: семейство всех распределений является сопряжённым любому распределению.

СОПРЯЖЁННЫЕ РАСПРЕДЕЛЕНИЯ

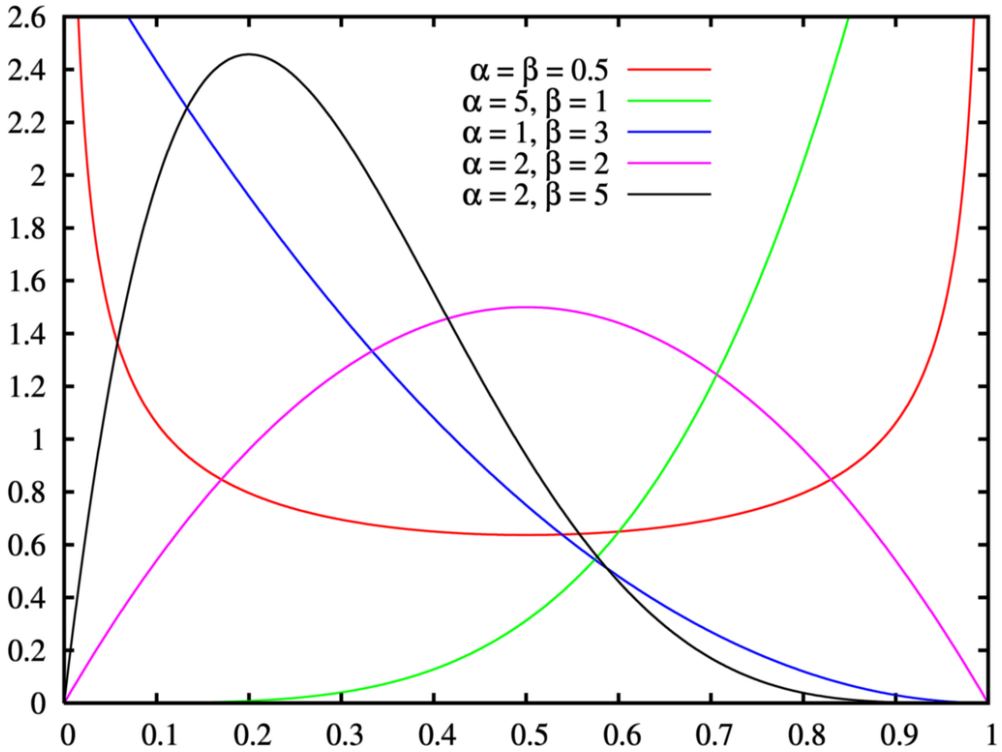
Сопряжённые распределения появляются из соображений удобства – чтобы апостериорное распределение имело тот же вид, что и априорное.

Если вместо априорного распределения подставить апостериорное для старых данных, то новое апостериорное будет получаться просто пересчётом параметров: $p(\Theta|D, D') \propto p(\Theta|D)p(D'|\Theta)$.

Для биномиального распределения сопряжённым является бета-распределение.

БЕТА-РАСПРЕДЕЛЕНИЕ





$$p(\Theta|\alpha,\beta) = \frac{\Theta^{\alpha-1}(1-\Theta)^{\beta-1}}{B(\alpha,\beta)}, \Theta \in [0;1]$$

Параметры бета-распределения можно интерпретировать как количество выпавших орлов α и количество решек β в *мыслимом* эксперименте.

Параметры апостериорного распределения теперь считаются совсем просто: $p(\Theta|\alpha+n,\beta+m) \propto p(\Theta|\alpha,\beta) \cdot p(D|\Theta)$

ОБУЧЕНИЕ КУБИКА

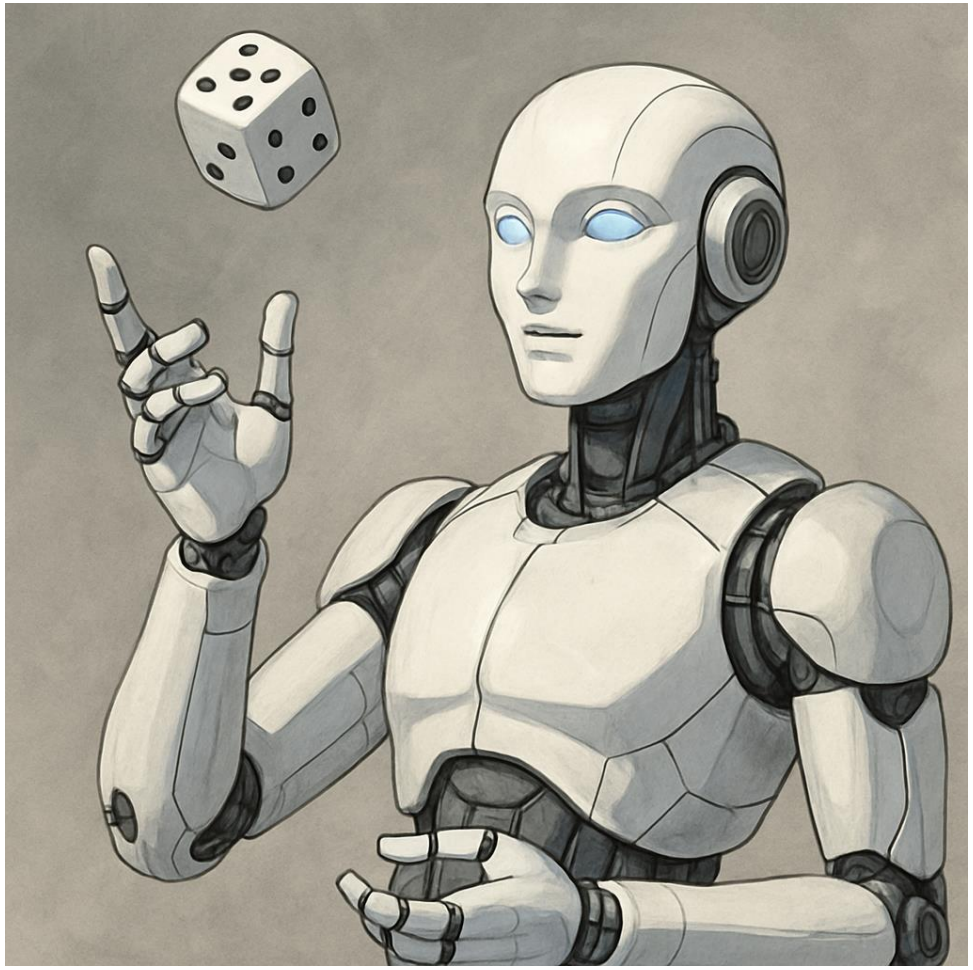
Теперь решим ту же задачу, но не для монетки, а для кубика с K гранями.

Результаты выпадения граней удобно представлять с помощью **прямого кодирования** (one-hot encoding), то есть булевого вектора с единственной единичкой на месте выпавшей грани. Например, событие «выпала 3-ая грань» можно закодировать вектором $(0, 0, 1, 0, 0, \dots, 0)^{\mathrm{T}}$.

Итак, набор данных $D = \left(\bar{d}_1, \bar{d}_2, \dots, \bar{d}_n\right)$ можно представить в виде $D = (n_1, n_2, \dots, n_K)$, где n_i – число раз, когда выпала i-ая грань.

Параметры модели $\Theta = (\Theta_1, \Theta_2 \dots, \Theta_K)^{\mathrm{T}}$, где $\Theta_i \in [0; 1]$ и $\sum_i \Theta_i = 1$.

ОБУЧЕНИЕ КУБИКА



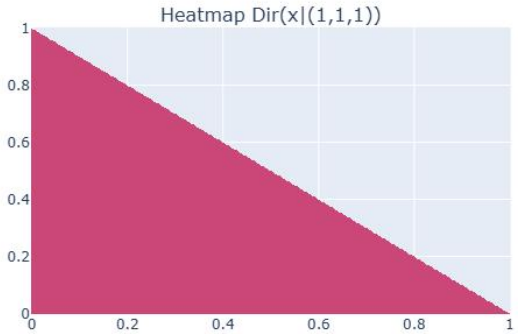
Функция правдоподобия:
$p(D|\overline{\Theta}) = \Theta^{n_1}\Theta^{n_2}\dots\Theta^{n_K}$.

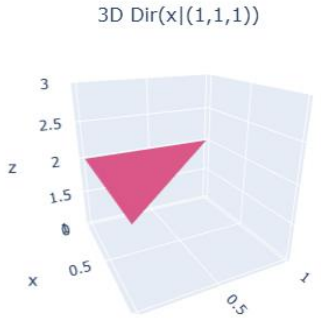
Апостериорное распределение:
$p(\overline{\Theta}|D) = \mathrm{Dir}(\overline{\Theta}|\bar{\alpha}+\bar{n})$.

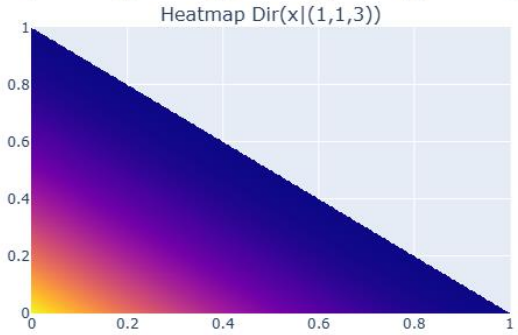
Предсказательное распределение:
$p(i|D) = \frac{n_i+\alpha_i}{\sum_j(n_j+\alpha_j)}$.

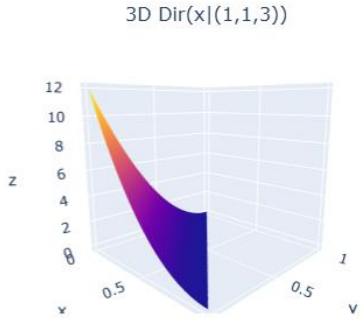


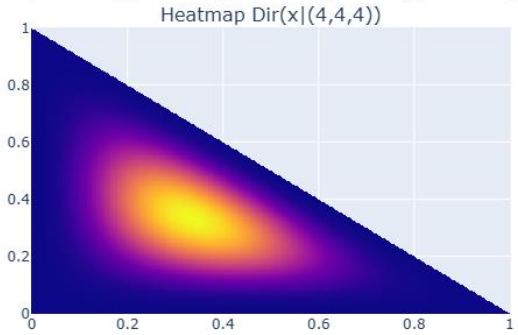
РАСПРЕДЕЛЕНИЕ ДИРИХЛЕ

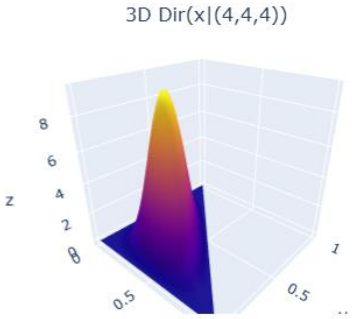










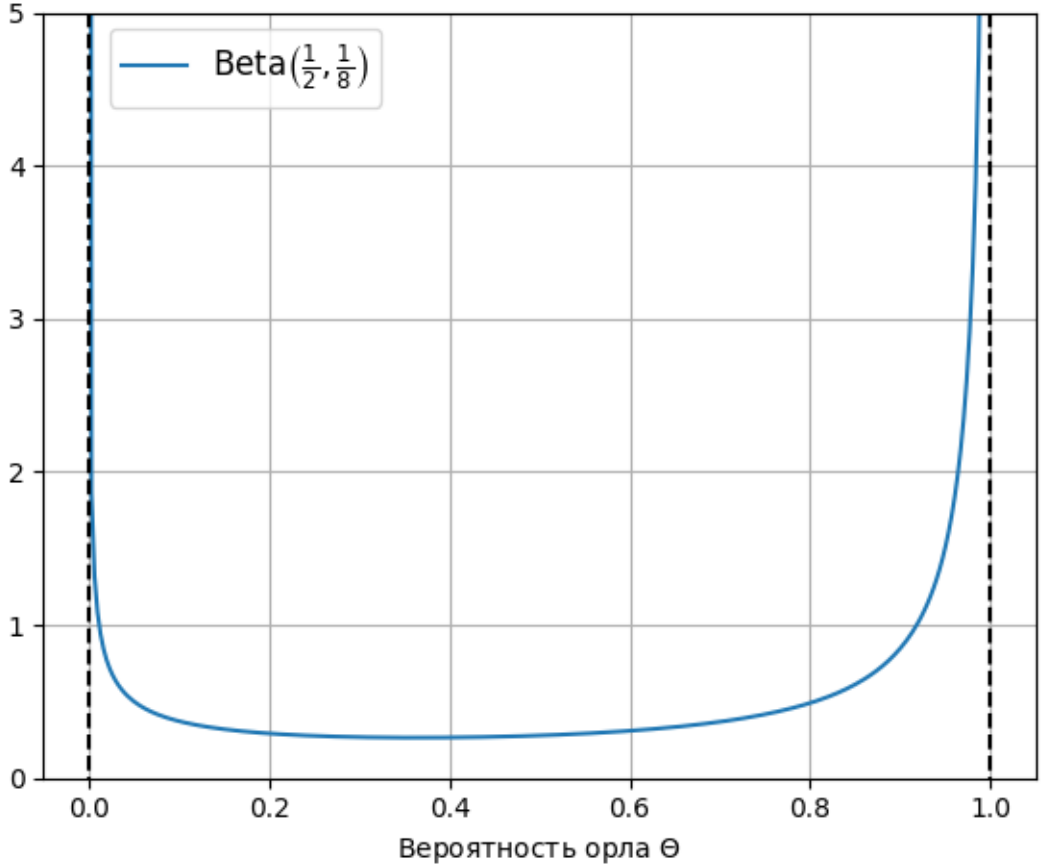


$$p(\overline{\Theta}|\overline{\alpha}) = \frac{1}{B(\overline{\alpha})}\Theta_1^{\alpha_1-1}\Theta_2^{\alpha_2-1}\cdots\Theta_K^{\alpha_K-1},$$

$$\Theta_i \in [0;1], \sum_i \Theta_i = 1.$$

Параметры α соответствуют количеству выпадения каждой грани в мыслимом эксперименте.

ДРОБНЫЕ ПАРАМЕТРЫ

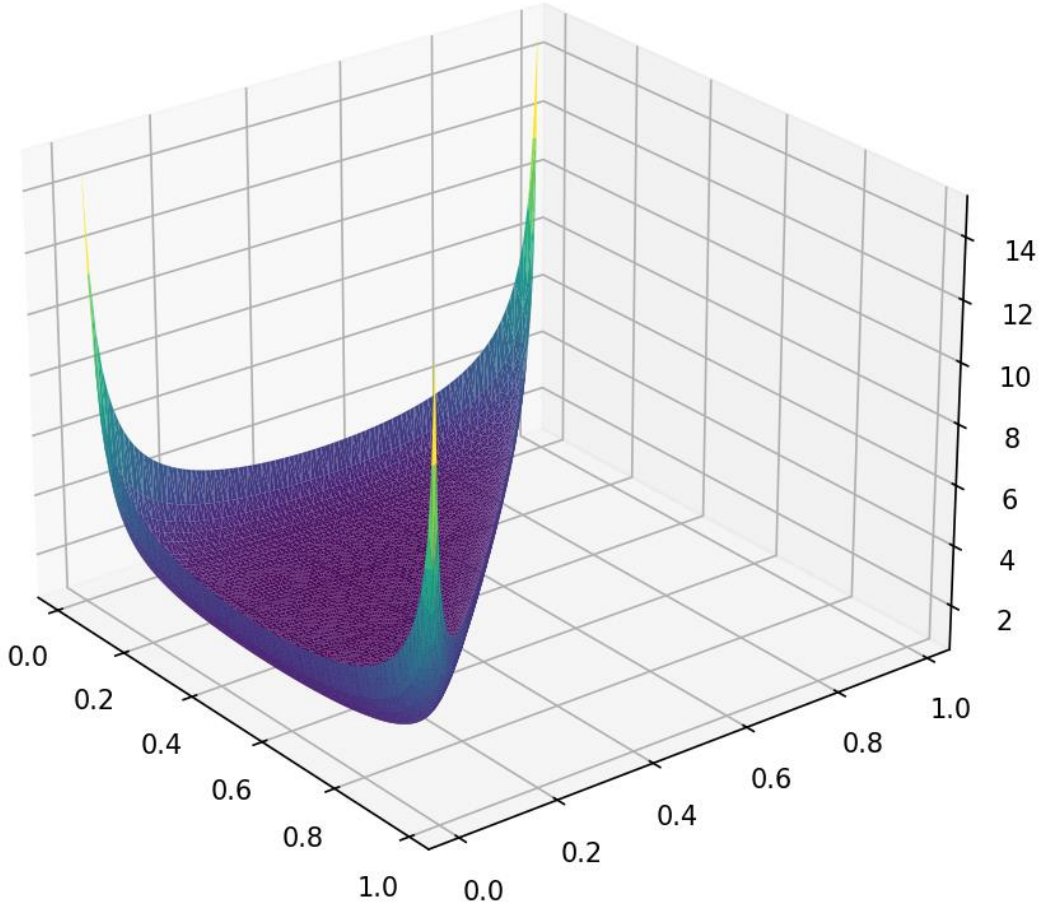


Что если выбрать дробные параметры от 0 до 1?

$$\text{Beta}\left(\Theta \middle| \frac{1}{2}, \frac{1}{2}\right) \propto \Theta^{-\frac{1}{2}}(1-\Theta)^{-\frac{1}{2}} = \frac{1}{\sqrt{\Theta(1-\Theta)}}.$$

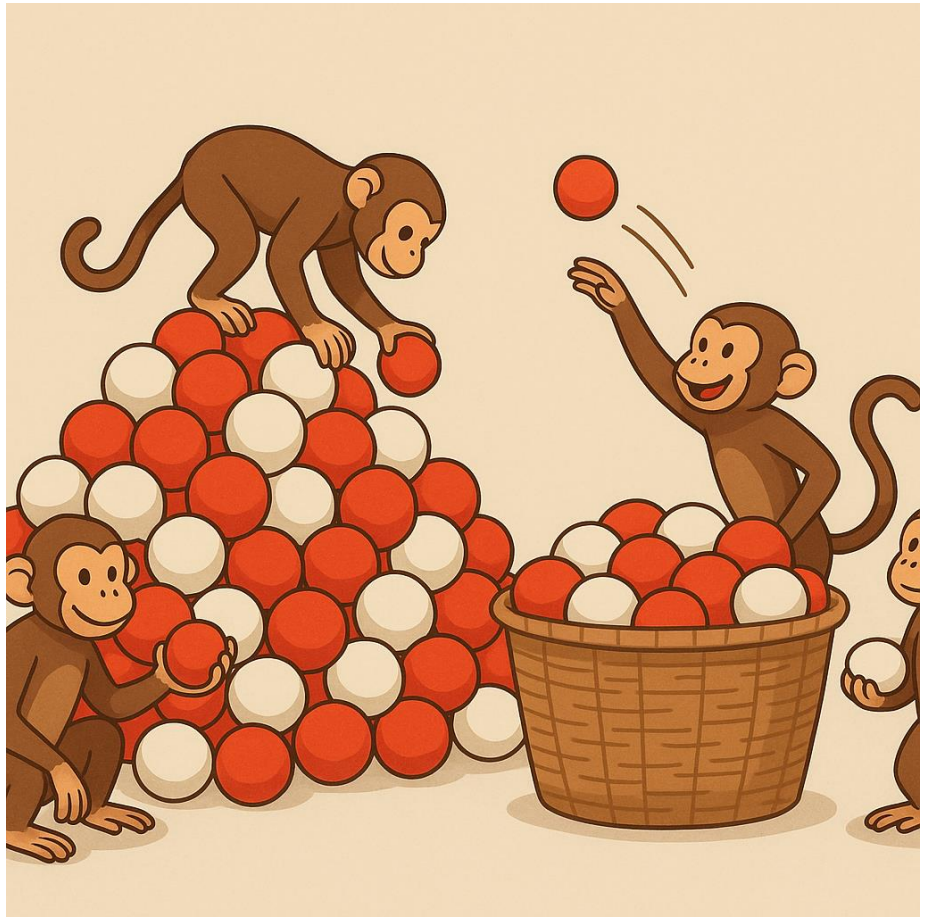
Вероятность «скапливается» у краёв, где один из параметров близок к 1, а остальные – к 0.

ДРОБНЫЕ ПАРАМЕТРЫ



Таким образом, дробные параметры в распределении Дирихле дают распределению *разреженность*. Это оказывается полезным, например, в *тематических моделях*, где документу соответствует только несколько подходящих тем. Главная тематическая модель даже носит название **Латентное Размещение Дирихле** (Latent Dirichlet Allocation, LDA).

КАК МОДЕЛИРОВАТЬ АБСОЛЮТНОЕ НЕЗНАНИЕ?



Что если в качестве априорного распределения для монетки мы положим мыслимый эксперимент с нулевым числом бросков $\mathrm{Beta}(0, 0)$?

В этом случае распределение перестанет быть вероятностным, но байесовский вывод всё ещё будет работать. Такие объекты называются **некорректными априорными распределениями** (Improper Prior Distributions).

НЕКОРРЕКТНЫЕ АПРИОРНЫЕ РАСПРЕДЕЛЕНИЯ



Некорректные априорные распределения, например, используются в обучении равномерного распределения и оказались крайне востребованными во Второй Мировой войне!

Этот материал курса оставлен для самостоятельного изучения 😀



Самостоятельно изучите тему обучения равномерного распределения. С. И. Николенко. Машинное обучение. Основы. С. 213-238

ЧТО ПОЧИТАТЬ?

Главы:

- 2.2 Вероятности в машинном обучении: теорема Байеса.
- 2.3 Байес в суде и сложности вероятностной интуиции.
- 2.4 Монетка и сопряжённые априорные распределения.
- 3.3 Немецкие танки, датская камбала и биномиальные обезьяны



С. И. Николенко. Машинное обучение. Основы. С. 100-149, 213-238